

Artículo de Investigación

DOI: <https://doi.org/10.61154/holopraxis.v10i1.4401>

Detección de enfermedades en plantas de papa (*Solanum tuberosum*) por medio de redes neuronales convolucionales

Detection of Diseases in Potato Plants (*Solanum tuberosum*) using Convolutional Neural Networks

Andy Mauricio López-Nasamues ^a, Marco Antonio Yandún-Velasteguí ^b, Anthony Alexander Quiranza-Arciniega ^c

^a Universidad Politécnica Estatal del Carchi, Carchi, Ecuador, Email: andy.lopez@upec.edu.ec, Orcid: <https://orcid.org/0000-0003-1948-8184>

^b Universidad Politécnica Estatal del Carchi, Carchi, Ecuador; Email: marco.yandun@upec.edu.ec, Orcid: <https://orcid.org/0000-0001-5627-9838>

^c Universidad Politécnica Estatal del Carchi, Carchi, Ecuador, Email: anthony.quiranza@upec.edu.ec, Orcid: <https://orcid.org/0009-0004-5378-6307>

Recibido: 3 de octubre de 2025

Aprobado: 16 de diciembre de 2025

RESUMEN

Esta investigación analizó el potencial de las redes neuronales convolucionales (CNN) para detectar enfermedades en plantas y tubérculos de papa (*Solanum tuberosum*), enfocándose en alternariosis (*Alternaria solani*), tizón tardío (*Phytophthora infestans*) y virosis (PVS). El objetivo principal fue explorar cómo estas redes modelarían patrones patológicos visuales, superando las limitaciones de los métodos tradicionales. Se empleó una metodología teórica y exploratoria, de diseño documental, que incluyó procesos de adquisición de imágenes RGB representativas, preprocesamiento (normalización, eliminación de ruido y realce de contraste), segmentación (con U-Net), extracción automática de características y clasificación mediante un modelo conceptual basado en EfficientNet-B3. Se integraron técnicas como módulos Squeeze-and-Excitation y Focal Loss para optimizar la detección de síntomas sutiles, sin recolección de datos empíricos, desde una perspectiva estudiantil. Los resultados simulados revelaron precisiones de detección del 93% para plantas sanas, 90% para plantas enfermas, 91% para tubérculos

sanos y 88% para tubérculos enfermos, relacionadas con perturbaciones en las imágenes: ruido ($\sigma=0.1$) con desviación de 80 y -10.5, desenfoque (5x5) con 83 y -7.5, y brillo ($\pm 30\%$) con 85 y -5-5. Estas superaron el diagnóstico visual tradicional (70% de precisión). En conclusión, el estudio contribuyó al avance en fitopatología computacional al identificar limitaciones teóricas, como la detección de síntomas internos en virosis, y proponer perspectivas académicas para sistemas futuros integrando modelos emergentes como Vision Transformers, fomentando habilidades en aprendizaje profundo.

Descriptores: Enfermedad de las plantas, Inteligencia artificial, Reconocimiento de formas. (Tesauro UNESCO)

ABSTRACT

This research analyzed the potential of convolutional neural networks (CNN) to detect diseases in potato plants and tubers (*Solanum tuberosum*), focusing on *Alternaria* leaf blight (*Alternaria solani*), late blight (*Phytophthora infestans*), and virosis (PVS). The main objective was to explore how these networks would model visual pathological patterns, overcoming the limitations of traditional methods. A theoretical and exploratory methodology was employed, with a documentary design that included processes of acquiring representative RGB images, preprocessing (normalization, noise removal, and contrast enhancement), segmentation (with U-Net), automatic feature extraction, and classification using a conceptual model based on EfficientNet-B3. Techniques such as Squeeze-and-Excitation and Focal Loss modules were integrated to optimize the detection of subtle symptoms, without empirical data collection, from a student perspective. The simulated results revealed detection accuracies of 93% for healthy plants, 90% for diseased plants, 91% for healthy tubers, and 88% for diseased tubers, related to image disturbances: noise ($\sigma=0.1$) with a deviation of 80 and -10.5, blurring (5x5) with 83 and -7.5, and brightness ($\pm 30\%$) with 85 and -5-5. These exceeded traditional visual diagnosis (70% accuracy). In conclusion, the study contributed to advances in computational plant pathology by identifying theoretical limitations, such as the detection of internal symptoms in virosis, and proposing academic perspectives for future systems integrating emerging models such as Vision Transformers, promoting skills in deep learning.

Descriptors: Plant disease, Artificial intelligence, Shape recognition. (UNESCO Thesaurus)

INTRODUCCIÓN

La papa (*Solanum tuberosum*) es un cultivo esencial en regiones andinas, pero su producción enfrenta amenazas por enfermedades fitopatológicas como alternariosis (*Alternaria solani*), tizón tardío (*Phytophthora infestans*), y virosis (PVS), que afectan tanto hojas como tubérculos (Lizarazo-Peña et al. 2020; Lucca 2022; Rosero et al. 2020; Quiranza, Moran 2022). Estas enfermedades comprometen la calidad y el rendimiento, generando pérdidas económicas significativas (Pedraza, 2022). La detección precisa y


temprana es un desafío científico crítico, limitado por la subjetividad y complejidad de los métodos tradicionales, como la inspección visual o los análisis moleculares. Este artículo presenta una investigación teórica exhaustiva sobre cómo las Redes Neuronales Convolucionales (CNN) podrían modelar patrones patológicos en imágenes, sentando las bases para un sistema futuro de diagnóstico automatizado (Kuswidiyanto2018).

Las CNN, una rama del aprendizaje profundo, son ideales para analizar imágenes debido a su capacidad para aprender jerarquías de características, desde bordes simples hasta patrones complejos como manchas o deformaciones Salina (2021). En este contexto, se explora cómo estas redes podrían detectar Alternariosis (anillos concéntricos en hojas), Tizón Tardío (manchas oscuras con halos), y Virosis o viruela (amarillamiento y deformación), tanto en hojas como en tubérculos (Rosero et al., 2020), se usan imágenes representativas, como un set de hojas sanas (Figura 1) y un set de hoja con síntomas tempranos de tizón tardío (Figura 2), para ilustrar cómo las CNN identificarían estos patrones teóricamente. En tubérculos, los síntomas superficiales, como manchas o necrosis, son detectables, mientras que la virosis interna plantea desafíos adicionales, desde una perspectiva académica, este trabajo busca contribuir al conocimiento académico, fomentando habilidades en computación y fitopatología, sin implicar aplicaciones prácticas inmediatas (Mitidieri, M. 2024).

La alternariosis, causada por el hongo *Alternaria solani*, se manifiesta como manchas oscuras con anillos concéntricos en las hojas, visibles en etapas avanzadas, bajo condiciones cálidas y húmedas (Rosero et al. 2020). El tizón tardío, inducido por el oomiceto *Phytophthora infestans*, prospera en alta humedad relativa (>90%) y temperaturas moderadas (15-25°C), generando manchas oscuras con halos amarillos que progresan a necrosis en pocos días. En tubérculos, causa lesiones oscuras y pudrición, afectando su valor comercial Cabezas (2024). La virosis, específicamente el virus PVS, produce síntomas foliares como amarillamiento, enrollamiento, y deformación, mientras que en tubérculos puede generar manchas internas indetectables sin cortes. Estas enfermedades, comunes en Carchi, requieren métodos de detección avanzados, y las CNN un escenario para modelar sus patrones visuales, como se ilustra en las Figuras 1 y 2.

Figura 1.


Ejemplo de hojas sana de papa (*Solanum tuberosum*). La uniformidad en color verde y la textura lisa serían identificadas por las capas convolucionales de una CNN como un patrón no patológico, analizando homogeneidad en los canales RGB.



Fuente: Universe Roboflow – Healty Potatoes

Figura 2.

Ejemplo teórico de hoja con síntomas tempranos de tizón tardío (*Phytophthora infestans*). Las manchas oscuras sutiles serían detectadas por filtros convolucionales sensibles a gradientes y contrastes, resaltando regiones patológicas.



Fuente: Universe Roboflow – diseased-plants

La fitopatología computacional integra biología, matemáticas, y computación para abordar problemas científicos complejos. En regiones como Carchi, donde la papa sustenta la economía local, el estudio de enfermedades es prioritario para mejorar la competitiva dentro de asociaciones productora del Tuberculo. Benalcazar (2024). Además, promueve el desarrollo de habilidades en aprendizaje profundo, análisis de imágenes, y pensamiento crítico, alineándose con los objetivos educativos de la Universidad Politécnica Estatal del Carchi.

Las CNN han revolucionado la clasificación de imágenes, logrando precisiones superiores al 90% en cultivos como arroz y tomate, (Poveda, 2025). Su capacidad para aprender características automáticamente las hace ideales para detectar síntomas sutiles, como los anillos de la alternariosis o el amarillamiento de la virosis. Este proyecto nos permitió explorar conceptos avanzados de visión computacional Bolaños et al (2020), usando imágenes representativas para ilustrar cómo las CNN podrían analizar patrones patológicos, preparando el terreno para investigaciones futuras.

La detección de enfermedades en cultivos ha evolucionado desde métodos manuales hasta enfoques computacionales avanzados. Esta sección revisa los métodos tradicionales, algoritmos clásicos, fundamentos de las CNN, y tendencias emergentes, destacando cómo las CNN podrían modelar patrones patológicos como los de las Figuras [1](#) y [2](#) (Rosero et al. 2020)

El propósito de esta investigación es analizar teóricamente cómo las redes neuronales convolucionales pueden detectar y modelar patrones patológicos de Alternariosis, Viruelas, tizón tardío, virosis y otras en plantas y tubérculos de papa mediante el procesamiento de imágenes representativas, identificando limitaciones y perspectivas para un sistema de diagnóstico automatizado futuro, todo desde una perspectiva estudiantil que fomente el avance académico en fitopatología computacional.

MÉTODOS

La investigación se desarrolló bajo un enfoque cuantitativo, debido a que se analizaron características visuales y métricas de precisión relacionadas con la identificación de enfermedades en cultivos a partir de imágenes. Se aplicó un tipo de investigación descriptiva, ya que se caracterizaron los métodos tradicionales y computacionales

empleados previamente para la detección de síntomas patológicos. El diseño fue documental, pues se recopiló, examinó y comparó información proveniente de artículos científicos, reportes técnicos y estudios especializados relacionados con técnicas de inspección visual, métodos inmunológicos, análisis espectral y modelos computacionales basados en algoritmos clásicos y redes neuronales convolucionales.

La inspección visual identificó síntomas foliares, como manchas o amarillamiento, con una precisión estimada de 50-70%. Sin embargo, su subjetividad depende de la experiencia del observador, y factores como la fatiga o la iluminación variable reducen su confiabilidad. En tubérculos, los síntomas internos, como los de la virosis, requieren análisis destructivo, limitando su utilidad teórica. Las CNN superarían estas limitaciones al analizar imágenes de manera objetiva, detectando patrones uniformes Figura 1. o anómalos Figura 2. Indicadas anteriormente.

Para la recolección de datos se utilizaron técnicas de revisión bibliográfica y análisis de contenido, empleando como instrumentos matrices de registro en las que se sistematizaron variables como precisión, sensibilidad, especificidad, costo operativo y requerimientos técnicos reportados en los estudios consultados. La población correspondió a la literatura científica publicada entre 2021 y 2025 en bases de datos especializadas, mientras que la muestra se seleccionó mediante un muestreo no probabilístico por criterios, considerando únicamente investigaciones que incluyeron mediciones cuantitativas de desempeño en la detección de enfermedades mediante imágenes o herramientas instrumentales.

Los datos obtenidos se interpretaron mediante análisis comparativo, identificando fortalezas y limitaciones de cada método según los resultados reportados. Se organizaron tendencias comunes entre estudios, y se contrastaron los valores de precisión, costo, accesibilidad y grado de automatización de los métodos revisados. La interpretación se centró en determinar en qué medida las técnicas computacionales basadas en aprendizaje profundo, como las redes neuronales convolucionales, superaban a los métodos tradicionales de inspección visual, ensayos inmunológicos o algoritmos clásicos de clasificación. Asimismo, se analizaron patrones de mejora asociados al preprocesamiento de imágenes, la segmentación automatizada y la inclusión de mecanismos avanzados como atención o regularización. Este análisis permitió establecer

la pertinencia y ventaja de aplicar arquitecturas modernas de visión computacional para el procesamiento e identificación de síntomas en imágenes agrícolas.

RESULTADOS

Esta sección discute los resultados teóricos esperados, basados en simulaciones conceptuales y análisis comparativos, ilustrando cómo las CNN detectarían enfermedades usando imágenes como las Figuras 1 y 2, y visualizando métricas con la Figura 3. Técnicas como el ensayo ELISA detectan patógenos con un 95% de sensibilidad, pero requieren 2-3 días de procesamiento (Gétaz y Castro, 2023). La PCR ofrece un 98% de especificidad, aunque su costo elevado (\$75-150 por muestra) y la necesidad de laboratorios especializados restringen su uso académico. Estas técnicas son inviables para análisis rápidos, mientras que las CNN podrían procesar imágenes en tiempo real, identificando síntomas visibles (Rosero et al. 2020).

Algoritmos Clásicos

Los algoritmos clásicos, como las máquinas de soporte vectorial (SVM) y Random Forest, han sido aplicados en fitopatología. Las SVM alcanzan un 82.1% de precisión en hojas, mientras que Random Forest logra un 79.3% (Olivares, 2021). Sin embargo, estos métodos dependen de características diseñadas manualmente como el color y la textura, lo que limita su capacidad para modelar patrones complejos como los de la Alternariosis o el Tizón tardío. Las CNN, en cambio, extraen características automáticamente, detectando detalles sutiles en imágenes como la Figura 2.

Fundamentos Matemáticos de CNN

Las CNN procesan imágenes mediante capas convolucionales que aplican filtros para extraer características, como bordes o texturas. La operación de convolución se define como:

$$(f * g)(x, y) = \sum_m \sum_n f(m, n)g(x - m, y - n)$$

donde f es la imagen (e.g., Figura 2) y g el filtro. La función de activación ReLU introduce no linealidad:

$$\text{ReLU}(x) = \max(0, x)$$

Estas operaciones permiten a las CNN detectar patrones patológicos, desde manchas

oscuras hasta deformaciones, como se observa en la Figura 2. Las capas de pooling reducen la dimensionalidad, preservando características clave, mientras que las capas densas clasifican estados sanos vs. Enfermo.

La segmentación aísla regiones de interés, como hojas o manchas. Métodos tradicionales, como k-means o el umbral de Otsu, identifican áreas enfermas basadas en color o intensidad, sin embargo, redes como U-Net integran segmentación en CNN, generando máscaras precisas para imágenes como la Figura 2, donde las manchas se distinguen del fondo esto facilita la detección de patrones patológicos específicos.

Las CNN procesan imágenes mediante la aplicación de filtros convolucionales capaces de extraer características locales como bordes, texturas y patrones complejos. Formalmente, la operación de convolución se define como:

$$(I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n)$$

Posteriormente, se introduce no linealidad mediante funciones de activación como ReLU:

$$ReLU(x) = \max(0, x)$$

Para la clasificación multiclase, se emplea la función Softmax:

$$P(y_i) = e^{z_i} / \sum_j e^{z_j}$$

Asimismo, para abordar el desbalance de clases, se considera el uso de la función Focal Loss:

$$FL(p_t) = -\alpha(1 - p_t)^\gamma \log(p_t)$$

Estas formulaciones permiten comprender cómo las CNN modelan patrones visuales asociados a síntomas fitopatológicos.

Preprocesamiento Avanzado

El preprocesamiento optimiza imágenes para las CNN, incluyendo:

- Normalización: Uniformidad en histogramas para reducir variaciones lumínicas.
- Eliminación de ruido: Filtros Gaussianos para aclarar detalles, como manchas en la Figura 2.
- Realce: Aumento de contraste para destacar síntomas, como el amarillamiento de la virosis (Rosero et al. 2020).

Estas técnicas aseguran que las CNN procesen imágenes de alta calidad, distinguiendo texturas sanas Figura 1 de patológicas.

Explicabilidad en CNN

Técnicas como Grad-CAM visualizan regiones influyentes en las predicciones, confirmando que las CNN priorizan manchas o deformaciones, alineándose con diagnósticos expertos López (2024). Por ejemplo, en la Figura 2, Grad-CAM resaltaría manchas oscuras, validando la detección de tizón tardío.

Exploramos VGG-16 (85% precisión), Inception-v3 (88%), y MobileNet (87%). Aunque efectivos, estos modelos son menos eficientes que EfficientNet-B3, que equilibra precisión y recursos, ideal para patrones como los de la Figura 2.

Tendencias Emergentes

Modelos como Vision Transformers (ViT) alcanzan un 94.2% de precisión, procesando imágenes como parches Retolaza (2025). Las redes generativas antagónicas (GANs) podrían generar imágenes sintéticas, simulando síntomas raros. Los Swin Transformers, con jerarquías de parches, son prometedores para imágenes agrícolas complejas, estas tendencias complementan el análisis de imágenes como las Figuras 1 y 2.

Tabla 1.
Comparativa de métodos teóricos

Método	Precisión (%)	Resolución (mm)
Inspección visual (Bock et al. 2019)	70.0	2.0
SVM (Kerkech, Hafiane, and Canals 2020)	82.1	1.0
Random Forest (Pydipati, Burks, and Lee 2006)	79.3	1.2
CNN Shallow (Ferentinos 2018)	89.7	0.8
ResNet-50 (Toda and Okura 2020)	93.5	0.5
ViT (Dosovitskiy et al. 2020)	94.2	0.4
Swin Transformer (Liu et al. 2021)	95.2	0.3
EfficientNet-B3 (Tan and Le 2019)	90.5	0.5

Fuente: Elaboración propia

Diseño Conceptual del Modelo

Proponemos un diseño teórico basado en EfficientNet-B3, adaptado para fitopatología:

- Capas base: Pesos preentrenados de ImageNet para acelerar el aprendizaje de patrones generales
- Módulos de atención: Squeeze-and-Excitation (SE) para priorizar regiones patológicas, como manchas en la Figura 2
- Función de pérdida: Focal Loss para abordar clases raras, con $\gamma = 2$ y $\alpha = 0.25$:

$$FL(p_t) = -\alpha_t(1 - p_t)^\gamma \log(p_t)$$

- Optimizador: AdamW con tasa de aprendizaje inicial $lr = 3 \times 10^{-4}$
- Capa de salida: Softmax para clasificar entre sano y enfermo (alternariosis, tizón tardío, virosis).

Este diseño optimizaría la detección de patrones en imágenes como las Figuras 1 y 2, equilibrando precisión y complejidad computacional.

Clasificación Teórica

La clasificación usaría una función softmax para asignar probabilidades a cada clase:

$$P(y_i) = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

donde z_i es la salida de la capa final. Esto permitiría distinguir hojas sanas (Figura 1) de enfermas (Figura 2), así como tubérculos sanos de aquellos con síntomas superficiales (Toda and Okura 2020). Las categorías incluirían:

- Planta sana: Color y textura uniformes, como en la Figura 1.
- Planta enferma: Alternariosis (anillos), tizón tardío (manchas, halos), virosis (amarillamiento).
- Tubérculo sano: Piel lisa, sin manchas.
- Tubérculo enfermo: Manchas, necrosis, arrugas.

Para garantizar el rigor matemático del proceso de clasificación multiclase, se incorpora explícitamente la función Softmax, empleada en la capa de salida de la red neuronal convolucional, definida como:

$$\text{Softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^C e^{z_j}}$$

donde z_i es la activación asociada a la clase i y C el número total de clases.

Asimismo, para abordar el desbalance entre clases, se considera la función de pérdida Focal Loss, formulada como:

$$\mathbf{FL}(p_t) = -\alpha(1 - p_t)^\gamma \log(p_t)$$

donde p_t representa la probabilidad predicha de la clase correcta, α es el factor de ponderación y γ el parámetro de enfoque.

La inclusión de ambas funciones refuerza el rigor matemático del modelo teórico propuesto y sustenta su capacidad para discriminar patrones patológicos en imágenes agrícolas.


Evaluación Simulada

Teóricamente, evaluaríamos el modelo con métricas como precisión, sensibilidad, especificidad, y F1-score, comparándolas con métodos tradicionales (70% de precisión) (Bock et al. 2019). La Figura 3 ilustra precisiones simuladas, mostrando la superioridad de las CNN

También analizaríamos la robustez ante perturbaciones, como ruido o variaciones lumínicas, que podrían afectar la detección de síntomas sutiles en la Figura 3.

Figura 3.

Uso de herramienta para determinar la salud de la planta por medio de visión por computadora




Fuente: Experimento propio

Métricas Teóricas Esperadas

Basado en la literatura, las CNN alcanzarían una precisión teórica de 90.5%, superando métodos tradicionales (70%) y algoritmos clásicos como SVM (82.1%), la Figura 4 muestra precisiones simuladas por categoría o clase seleccionada:

Figura 4.


Preparación del modelo de detección de enfermedades



Fuente: Experimento propio

Figura 5.

Pruebas de uso de aplicativo en donde se determina un 89% de enfermedad detectada de Alternaria.



Fuente: Experimento propio

Del proceso de captura, preprocesamiento, clasificación en las clases seleccionadas, entrenamiento y despliegue se puede determinar que existe determinadas perturbaciones entre la precisión y la desviación en la figura 5 la precisión en una clase de 89% en la tabla 2, se muestra los resultados de todo el proceso.

Tabla 2.

Sensibilidad teórica a perturbaciones

Perturbación	Precisión (%)	Desviación (%)
Ruido ($\sigma = 0.1$)	80	-10.5
Desenfoque (5x5)	83	-7.5
Brillo ($\pm 30\%$)	85	-5.5

Fuente: Elaboración propia

Comparación con Métodos Teóricos

El diseño con EfficientNet-B3 (90.5%) superaría SVM (82.1%) y Random Forest (79.3%), pero estaría por debajo de ResNet-50 (93.5%) y ViT (94.2%) visualiza esta comparación, destacando la capacidad de las CNN para modelar patrones que puede detectar hojas sanas u hojas enfermas como las de Figuras 4 y Figura 5.

DISCUSIÓN

Esta sección analiza las implicaciones teóricas de usar CNN para detectar enfermedades en papa, profundizando en cómo modelarían patrones en imágenes como las Figuras [1](#) y [2](#), y explorando limitaciones y perspectivas futuras.

Teoría de Clasificación con CNN

Las CNN modelan jerarquías de características, desde bordes simples hasta patrones complejos, como los anillos de la alternariosis o las manchas del tizón tardío en la Figura 1, detectarían uniformidad en color y textura, clasificando la hoja como sana. En la Figura 2, identificarían contrastes sutiles, indicando tizón tardío temprano. Esta capacidad supera la inspección visual, que es subjetiva y menos precisa. Según Mohanty et al. (2016), esta capacidad jerárquica permite que los modelos aprendan representaciones visuales directamente desde los datos sin necesidad de ingeniería manual de

características, lo que resulta especialmente adecuado para el análisis automatizado de imágenes foliares con síntomas variables.

Análisis de Patrones Visuales

El proceso de detección involucra varias etapas:

- Capas iniciales: Detectan bordes y colores, como el verde uniforme (Figura 1) o las manchas oscuras (Figura 2)
- Capas intermedias: Modelan texturas, como irregularidades en hojas enfermas.
- Capas profundas: Reconocen patrones complejos, como halos o deformaciones (Figura 5), en el despliegue del aplicativo.

De acuerdo con Barbedo (2018), este enfoque multinivel resulta crucial en fitopatología, ya que los síntomas visuales suelen variar en forma, tamaño e intensidad incluso dentro de una misma enfermedad. Los módulos SE mejorarían la atención, enfocándose en regiones patológicas, como manchas en la Figura 2, mientras que Focal Loss priorizaría síntomas raros, como los de la virosis. A continuación, una comparativa con diferentes modelos.

Tabla 3.

Comparativa teórica con benchmarks

Modelo	Precisión (%)	Complejidad
SVM (Kerkech, Hafiane, and Canals 2020)	82.1	Media
Random Forest (Pydipati, Burks, and Lee 2006)	79.3	Baja
ResNet-50 (Toda and Okura 2020)	93.5	Alta
ViT (Dosovitskiy et al. 2020)	94.2	Muy alta
Swin Transformer (Liu et al. 2021)	95.2	Muy alta
EfficientNet-B3 (Tan and Le 2019)	90.5	Media

Fuente: Elaboración propia

Patrones Visuales en Fitopatología

Las CNN detectarían patrones específicos:

- **Alternariosis:** Anillos concéntricos, detectados por filtros sensibles a formas circulares.

- **Tizón tardío:** Manchas oscuras con halos, como en la Figura 2, identificadas por gradientes de color.
- **Virosis:** Amarillamiento y deformación, capturados por cambios en canales RGB
- En tubérculos, las CNN reconocerían manchas superficiales, pero los síntomas internos de virosis serían un desafío la Figura 1 ilustra un patrón no patológico, con homogeneidad que las capas iniciales detectarían fácilmente.

Adicional las clases mencionadas como: Ciclamen, Mildiu

Exploración de Modelos Emergentes

Modelos como Swin Transformers ofrecen un 95.2% de precisión, dividiendo imágenes en parches jerárquicos, ideales para patrones complejos (Liu et al. 2021). Las GANs generarían imágenes sintéticas, simulando síntomas como los de la Figura 2, enriqueciendo el análisis los enfoques multimodales, combinando imágenes con datos climáticos, mejorarían la detección temprana.

Datos Sintéticos

Las GANs podrían generar imágenes realistas de hojas y tubérculos, simulando condiciones raras, como virosis avanzada, complementando imágenes reales como las Figuras 1 y 2 Esto reduciría la dependencia de datos naturales, un desafío en fitopatología.

Incertidumbre en Clasificación

Modelos bayesianos incorporarían incertidumbre, mejorando la confianza en predicciones para imágenes ambiguas, como síntomas tempranos en la Figura 2 La incertidumbre bayesiana se calcula como:

$$p(y|x, D) = \int p(y|x, w)p(w|D)dw$$

donde w son los pesos y D los datos. Esto sería útil para virosis, con síntomas variables (Barbedo 2019).

Datos Multimodales

Integrar imágenes con datos climáticos (humedad, temperatura) podría anticipar condiciones favorables para enfermedades, mejorando la detección teórica, por ejemplo, la Figura 2 podría correlacionarse con alta humedad, indicando tizón tardío.

El análisis teórico sugiere que las CNN poseen una capacidad superior para modelar jerarquías de características visuales, desde patrones simples hasta estructuras patológicas complejas. No obstante, su desempeño depende de la calidad de las imágenes y del preprocesamiento aplicado.

Limitaciones del estudio

El carácter teórico del trabajo constituye su principal limitación, al no incluir validación empírica ni entrenamiento real de modelos. Asimismo, la detección de síntomas internos en tubérculos, especialmente en virosis, sigue representando un desafío incluso para enfoques computacionales avanzados.

CONCLUSIONES

Esta investigación teórica analiza cómo las redes neuronales convolucionales podrían detectar Alternarías, Viruela, Ciclamen, Mildiu y Moho Polvoriento en plantas y tubérculos de papa, usando imágenes representativas (Figuras 1, 2) y visualizaciones (Figura 3,4, 5) para ilustrar procesos. Los aportes incluyen:

- Análisis exhaustivo de procesos teóricos (preprocesamiento, segmentación, clasificación), detallando cómo las CNN detectarían patrones patológicos (Rosero et al. 2020).
- Evaluación conceptual de EfficientNet-B3, estimando un 90.5% de precisión, superando métodos tradicionales (Yandún, Rivera, Herrera 2024).
- Identificación de limitaciones, como síntomas tempranos (Figura 2) y virosis interna (Barbedo, 2019).
- Propuesta de modelos emergentes, como ViT, GANs, y enfoques bayesianos, para investigaciones futuras
- El estudio demuestra, desde una perspectiva teórica, que las Redes Neuronales Convolucionales presentan un alto potencial para la detección de enfermedades en el cultivo de papa mediante imágenes digitales.
- La precisión estimada del 90.5% para EfficientNet-B3 corresponde a una proyección basada en literatura reciente y análisis conceptual. Se puede mencionar que estas tecnologías representan una alternativa prometedora para futuros sistemas de

diagnóstico automatizado, especialmente por su equilibrio entre precisión y eficiencia computacional.

Agradecimientos

Agradecemos a Anderson Rodríguez, José Mafla y Israel Salazar, estudiantes de la Universidad Politécnica Estatal del Carchi por su colaboración en la investigación.

Conflicto de interés

Los autores no tienen conflictos de interés

Financiación

Este proyecto no contó con ninguna fuente de financiación

Responsabilidades Éticas

El proyecto fue aprobado por el comité de ética de la institución.

REFERENCIAS

- Benalcázar-Sánchez, R. N., & Urresta-Yépez, R. F. (2024). Estrategias para mejorar la competitividad en las asociaciones de los productores de papa en el cantón Bolívar, provincia del Carchi. *Journal of Economic and Social Science Research*, 4(4), 1-24.
<https://economicsocialresearch.com/index.php/home/article/view/127>
- Bolaños, A., Gualpa, J. C., Benavides, Á. A., Yandún-Velasteguí, M. A., & Lascano Rivera, S. B. (2020). Sistema de clasificación de rosas de la variedad explorer usando visión por computadora: Sorting system for roses of the explorer variety using computer vision. In *Conference Proceedings (Machala)* (Vol. 4, No. 1, pp. 209-217). Universidad Técnica de Machala.
<https://dialnet.unirioja.es/servlet/articulo?codigo=9358819>
- Cabezas Dávila, B. M. (2024). *Análisis de daños causado por Ralstonia solanacearum en cultivo de papa* (Bachelor's thesis, BABAHOYO: UTB, 2024).
<https://dspace.utb.edu.ec/items/257418cf-f142-4ffd-b063-f473a7c26ffb>

- Gétaz, L., & Castro Soto, M. D. R. (2023). Sensibilidad de la prueba ELISA para detectar los anticuerpos IgG contra el *Strongyloides stercoralis* en pacientes inmunocomprometidos. *Gaceta Médica Boliviana*, 46(1), 14-17. <https://doi.org/10.47993/gmb.v46i1.613>
- Kuswidiyanto LW, Noh H-H, Han X. (2022). Plant Disease Diagnosis Using Deep Learning Based on Aerial Hyperspectral Images: A Review. *Remote Sensing*. 2022; 14(23):6031. <https://doi.org/10.3390/rs14236031>
- Lizarazo-Peña, P. A., Fornaguera-Espinoza, F., Núñez-López, C. E., Cruz-Gutiérrez, N. A. & Moreno-Fonseca, L. P. (2020). Effect of gibberellic acid-3 and 6-benzylaminopurine on dormancy and sprouting of potato (*Solanum tuberosum* L.) tubers cv. Diacol Capiro. *Agronomía Colombiana*, 38(2), 178–189. <https://doi.org/10.15446/agron.colomb.v38n2.82231>
- López Arredondo, F y Camargo Espinosa, J. (2024). Estudio comparativo de técnicas basadas en Grad-CAM para la explicabilidad de redes neuronales. Universidad de Ibagué. <https://hdl.handle.net/20.500.12313/4657>
- Lucca, F. (2022). ATN/RF 16678 Alerta temprana para el manejo del Tizón tardío de la papa Producto 18. Instructivo para toma de muestras. [Microsoft Word - Producto 18. Instructivo de toma de muestras.docx](#)
- Mitidieri, M. (2024). Manejo Sanitario de Cultivos Frutícolas en el Norte Argentino| Compiladores: Natalia Meneguzzi Margarita Jaramillo, 79. https://www.researchgate.net/profile/Maria-Carabajo-Romero/publication/386534245_Manejo_Sanitario_de_Cultivos_Fruticolas_en_el_Norte_Argentino/links/6754644eea30b90cbc63a3c2/Manejo-Sanitario-de-Cultivos-Fruticolas-en-el-Norte-Argentino.pdf#page=80
- Olivares, B. O., Vega, A., Calderón, M. A. R., Rey, J. C., & Lobo, D. (2021). Clasificación de zonas afectadas por la marchitez en banano: una aplicación con algoritmos de Machine Learning en Venezuela Classification of areas affected by banana wilt: an application with Machine Learning algorithms in Venezuela. [483398345-libre.pdf](#)
- Pedraza, L., Sánchez, F., Arias, V., Moreno, M. y Sánchez, L. (2022). Enfermedades emergentes y reemergentes de plantas en Latinoamérica: Una revisión. *Revista de Investigación Agraria y Ambiental*, 13(2), 15 – 51.

DOI: <https://doi.org/10.22490/21456453.4639>

- Poveda Castillo, Y. C. (2025). Modelo de detección de enfermedades en cultivos aplicando deep learning y datos sintéticos generados por redes generativas adversarias (GANs). <https://repository.libertadores.edu.co/items/dbc77ba0-9a0b-415a-a440-8d5aeb5a1a3d>
- Quiranza, A., Moran, D. (2022) “Visión Artificial para la detección de enfermedades en el cultivo de papa”, <http://repositorio.upec.edu.ec/handle/123456789/1705>
- Retolaza-Carlos, O. G. (2025). Detección de imágenes DeepFake con Vision Transformers (ViT). <https://hdl.handle.net/11117/11574>
- Rosero, N., Cabrera, J., Anrango, M., Yandún-Velastegui, M., Lascano, S. (2020). “Detección de Enfermedades En Cultivos de Papa Usando Procesamiento de Imágenes.” *Revista Cumbres* 6 (1): 43–52. <https://dialnet.unirioja.es/servlet/articulo?codigo=8228807>
- Salina, M. D. (2021). Deep Learning aplicado al procesamiento de imágenes para la detección de objetos reciclables. <https://biblioarchivo.unaj.edu.ar/uploads/971878f2e329cf76f250892cd859eec0645e9938.pdf>
- Yandún-Velasteguí, M., Rivera, L., & Herrera, J. (2024, September). Automatic Disease Detection in Physalis Peruviana Based on Image, a Review Systematic. In *Colombian Conference on Computing* (pp. 168-183). Cham: Springer Nature Switzerland. https://link.springer.com/chapter/10.1007/978-3-031-75233-9_13