



UNIVERSIDAD CÉSAR VALLEJO

**FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS**

**Visión artificial para la identificación de antracnosis en cultivos
de mango de la región Piura**

TESIS PARA OBTENER EL TÍTULO PROFESIONAL DE:

Ingeniero de Sistemas

AUTORES:

Salvador Ramirez, Aaron (orcid.org/0000-0002-2264-7847)

Tavara Araujo, María Elena (orcid.org/0000-0001-7897-3492)

ASESOR:

Dr. Tavara Ramos, Anthony Paul (orcid.org/0000-0002-4159-930X)

LÍNEA DE INVESTIGACIÓN:

Sistemas de información y comunicaciones

LÍNEA DE RESPONSABILIDAD SOCIAL UNIVERSITARIA:

Desarrollo sostenible y adaptación al cambio climático

PIURA – PERÚ

2024

Declaratoria de autenticidad del asesor



UNIVERSIDAD CÉSAR VALLEJO

**FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS**

Declaratoria de Autenticidad del Asesor

Yo, TAVARA RAMOS ANTHONY PAUL, docente de la FACULTAD DE INGENIERÍA Y ARQUITECTURA de la escuela profesional de INGENIERÍA DE SISTEMAS de la UNIVERSIDAD CÉSAR VALLEJO SAC - PIURA, asesor de Tesis titulada: "Visión artificial para la identificación de antracnosis en cultivos de mango de la región Piura", cuyos autores son TAVARA ARAUJO MARIA ELENA, SALVADOR RAMIREZ AARON, constato que la investigación tiene un índice de similitud de 8%, verificable en el reporte de originalidad del programa Turnitin, el cual ha sido realizado sin filtros, ni exclusiones.

He revisado dicho reporte y concluyo que cada una de las coincidencias detectadas no constituyen plagio. A mi leal saber y entender la Tesis cumple con todas las normas para el uso de citas y referencias establecidas por la Universidad César Vallejo.

En tal sentido, asumo la responsabilidad que corresponda ante cualquier falsedad, ocultamiento u omisión tanto de los documentos como de información aportada, por lo cual me someto a lo dispuesto en las normas académicas vigentes de la Universidad César Vallejo.

PIURA, 03 de Diciembre del 2024

Apellidos y Nombres del Asesor:	Firma
TAVARA RAMOS ANTHONY PAUL DNI: [REDACTED] ORCID: 0000-0002-4159-930X	Firmado electrónicamente por: ATAVARAR el 06-12- 2024 12:27:06

Código documento Trilce: TRI - 0937738

Declaratoria de originalidad del autor(es)



UNIVERSIDAD CÉSAR VALLEJO

**FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS**

Declaratoria de Originalidad de los Autores

Nosotros, TAVARA ARAUJO MARIA ELENA, SALVADOR RAMIREZ AARON estudiantes de la FACULTAD DE INGENIERÍA Y ARQUITECTURA de la escuela profesional de INGENIERÍA DE SISTEMAS de la UNIVERSIDAD CÉSAR VALLEJO SAC - PIURA, declaramos bajo juramento que todos los datos e información que acompañan la Tesis titulada: "Visión artificial para la identificación de antracnosis en cultivos de mango de la región Piura", es de nuestra autoría, por lo tanto, declaramos que la Tesis:

1. No ha sido plagiada ni total, ni parcialmente.
2. Hemos mencionado todas las fuentes empleadas, identificando correctamente toda cita textual o de paráfrasis proveniente de otras fuentes.
3. No ha sido publicada, ni presentada anteriormente para la obtención de otro grado académico o título profesional.
4. Los datos presentados en los resultados no han sido falseados, ni duplicados, ni copiados.

En tal sentido asumimos la responsabilidad que corresponda ante cualquier falsedad, ocultamiento u omisión tanto de los documentos como de la información aportada, por lo cual nos sometemos a lo dispuesto en las normas académicas vigentes de la Universidad César Vallejo.

Nombres y Apellidos	Firma
AARON SALVADOR RAMIREZ DNI: [REDACTED] ORCID: 0000-0002-2264-7847	Firmado electrónicamente por: SASALVADORS el 03-12-2024 12:50:51
MARIA ELENA TAVARA ARAUJO DNI: [REDACTED] ORCID: 0000-0001-7897-3492	Firmado electrónicamente por: MTAVARAAR21 el 03-12-2024 12:33:05

Código documento Trilce: TRI - 0937739

Dedicatoria

En primer lugar, a Dios, por acompañarnos en cada momento de este camino, por ser nuestra fortaleza y la fuente de sabiduría que nos ha sostenido en este camino. A nuestras familias, quienes, con su constante apoyo y su amor incondicional, han sido nuestro mayor pilar en los momentos de dificultad y celebración.

Agradecimiento

En primer lugar, agradecemos a Dios, quien nos brindó la fuerza y conocimiento necesario para culminar este importante proyecto.

A nosotros mismos, por la resiliencia, el compromiso y la capacidad de superar juntos cada obstáculo que se presentó. Este logro es testimonio de nuestro esfuerzo compartido.

A nuestras familias, quienes nos apoyaron de manera incondicional, nos brindaron aliento en los momentos difíciles y celebraron cada pequeño avance.

A nuestros asesores y profesores, por su orientación, paciencia y valiosas enseñanzas, que enriquecieron significativamente nuestro trabajo.

A las instituciones y personas que contribuyeron con recursos, información y orientación, facilitando la realización de esta tesis.

Índice de Contenido

Caratula	i
Declaratoria de autenticidad del asesor	2
Declaratoria de originalidad del autor(es).....	3
Dedicatoria	4
Agradecimiento	5
Índice de Contenido	6
Índice de tablas	7
Índice de figuras	8
Resumen	9
Abstract	10
I. INTRODUCCIÓN	11
II. METODOLOGÍA	21
III. RESULTADOS.....	32
IV. DISCUSIÓN	35
V. CONCLUSIONES	40
VI. RECOMENDACIONES	41
REFERENCIAS.....	42
ANEXOS	

Índice de tablas

TABLA I DETALLE DE LAS RELACIONES CLAVE ENTRE LAS CAPAS CONVOLUCIONALES Y DE POOLING.....	26
---	----

TABLA II RESULTADOS OBTENIDOS DE LAS PRUEBAS REALIZADAS EN 80 PLANTONES DE MANGO.....	32
---	----

Índice de figuras

Figura 1: Estructura CNN.	24
Figura 2: Imágenes obtenidas al aplicar los filtros de la CNN.	25
Figura 3: Comparación visual entre una imagen y su versión procesada tras aplicar Max Pooling.....	25
Figura 4: Escala HSV con graduación de Matriz (X) y Saturación (Y).....	27
Figura 5: Variedad de tonalidades presentes en las hojas de mango destaca su diversidad cromática.	28
Figura 6: Resultados obtenidos tras aplicar umbralización por capas a la imagen.	28
Figura 7: Representación gráfica de un kernel para las operaciones morfológicas que son aplicadas a las imágenes.	29
Figura 8: Segmentación de la hoja mediante umbralización y operaciones morfológicas.	30
Figura 9: Resultados final de la detección de antracnosis tras el uso de CNN.	30
Figura 10: Diagrama de barras - Resultados de las métricas	33
Figura 11: Prueba de Chi-cuadrado: Región de aceptación y rechazo	35

Resumen

La detección temprana de antracnosis en cultivos de mango representa un desafío crítico para la agricultura en Piura, Perú, donde esta enfermedad causa pérdidas de hasta 51% en campo y 30% en postcosecha. Este estudio desarrolló un sistema de visión artificial basado en redes neuronales convolucionales (CNN) para la detección automatizada de antracnosis en cultivos de mango. Se implementó una arquitectura CNN de cuatro capas utilizando TensorFlow, combinada con técnicas de segmentación mediante OpenCV para el procesamiento de imágenes. El sistema fue evaluado en condiciones de campo con 80 plantones de mango (48 infectados, 32 sanos), alcanzando una precisión del 95%, sensibilidad del 93.75% y especificidad del 96.88%. El modelo demostró robustez en la identificación de patrones característicos de antracnosis bajo diferentes condiciones ambientales y de iluminación, superando el umbral objetivo del 85% de precisión. Los resultados validan la efectividad del sistema como herramienta de diagnóstico temprano, contribuyendo al desarrollo de soluciones tecnológicas accesibles para el manejo preventivo de enfermedades en cultivos de mango.

Palabras clave: Detección de enfermedades, inteligencia artificial, enfermedades de las plantas, reconocimiento

Abstract

Early detection of anthracnose in mango crops represents a critical challenge for agriculture in Piura, Peru, where this disease causes losses of up to 51% in the field and 30% in postharvest. This study developed a computer vision system based on convolutional neural networks (CNN) for the automated detection of anthracnose in mango crops. A four-layer CNN architecture was implemented using TensorFlow, combined with segmentation techniques using OpenCV for image processing. The system was evaluated under field conditions with 80 mango seedlings (48 infected, 32 healthy), reaching an accuracy of 95%, sensitivity of 93.75% and specificity of 96.88%. The model demonstrated robustness in identifying characteristic patterns of anthracnose under different environmental and lighting conditions, surpassing the target threshold of 85% accuracy. The results validate the effectiveness of the system as an early diagnosis tool, contributing to the development of accessible technological solutions for the preventive management of diseases in mango crops.

Keywords: Disease Detection, Artificial Intelligence, Plant Disease, Recognition

I. INTRODUCCIÓN

El cultivo del mango (*Mangifera indica* L.) representó un pilar fundamental en la economía agrícola global, con una producción mundial que alcanzó 51 millones de toneladas en 2019 [1]. En más de 90 países se cultivan más de 160 variedades, destacando el 'Keitt', el 'Kent' y el 'Tommy Atkins', como las preferidas, tanto por los productores como por los consumidores. Estas variedades son apreciadas no solo por su alto valor nutricional y contenido de minerales, sino también por sus características organolépticas, como su aroma, textura y sabor [2]. Estas cualidades han permitido que el mango sea altamente demandado en mercados internacionales, consolidándose como un producto atractivo para el comercio global [3].

Según datos de la Organización de las Naciones Unidas para la Alimentación y la Agricultura [4], el mango ocupó una posición prominente entre las frutas más cultivadas y comercializadas a nivel global. Actualmente, se cultivan más de 160 variedades de mango en más de 90 países, lo que refleja la importancia económica y comercial de esta fruta. Estas variedades compartieron características óptimas, como su capacidad de adaptarse a regiones con altas temperaturas y la preferencia por suelos bien drenados, lo que asegura su desarrollo en entornos tropicales y subtropicales.

En términos de consumo, el mango ha tenido una gran aceptación a nivel mundial, con un consumo per cápita promedio anual de aproximadamente 5.5 kilogramos por habitante. Este nivel de consumo contribuyó significativamente a la generación de ingresos para los agricultores y a la economía rural, especialmente en países donde el mango es un cultivo principal. Asimismo, el mango desenvuelve un papel crucial en la seguridad alimentaria, ya que es una fuente rica en vitaminas A y C, antioxidantes y fibra dietética, lo que lo convierte en un alimento esencial para muchas comunidades.

En la región de Piura, Perú, el mango ha emergido como un motor económico de gran relevancia, integrándose como uno de los productos agrícolas más exportados,

generando empleo y oportunidades de desarrollo rural [5].

Sin embargo, la antracnosis emergió como una amenaza crítica para la producción, causando pérdidas de hasta 51% en campo y 20-30% en postcosechas. El agente causal, *Colletotrichum* sp., presenta un comportamiento hemibiotrófico complejo que dificulta su detección temprana y control efectivo. El endofitismo es un modo de vida del hongo cuyo impacto en la patogénesis aún no se comprende del todo. La antracnosis representa la enfermedad más perjudicial en los cultivos de mango, afectando directamente a los frutos, reduciendo la calidad de la cosecha y ocasionando pérdidas económicas considerables [6].

En la región Piura, Perú, donde el mango es uno de los más destacados para la exportación, la detección tardía de antracnosis y el manejo empírico de los cultivos limitan la productividad. Los métodos tradicionales de detección resultan laboriosos y costosos [7]. Además, la identificación precisa de las enfermedades puede llegar a ser compleja, lo que dificulta la implementación de medidas de control efectivas y oportunas.

En este contexto, [5] se considera poco probable alcanzar los niveles máximos de productividad por unidad de superficie, dado que la necesidad de mejorar el manejo empírico de las labores de producción del cultivo de mango. Se requirió un aumento en la implementación y conocimiento de nuevas y mejores técnicas de manejo integrado de plagas y prácticas agrícolas sostenibles para mitigar estos impactos y asegurar la continuidad y calidad de la producción de mango en la región.

La adopción de tecnologías avanzadas y prácticas agrícolas innovadoras fue crucial para superar estos desafíos. La integración de técnicas de manejo integrado de plagas (MIP) y la agricultura de precisión podrá mejorar la detección temprana y el control de enfermedades, optimizando el rendimiento y la calidad del mango. Además, la capacitación continua de los agricultores en estas nuevas técnicas será fundamental para mejorar la sostenibilidad y rentabilidad del cultivo en Piura [8].

Montenegro [9] resaltó la efectividad de la aplicación de la inteligencia artificial en la

detección de plagas en cultivos de mango. El desarrollo de un modelo basado en una red neuronal bidimensional logró alcanzar una precisión y unas métricas de exactitud del 100%, así como una función de pérdida del 0,001%. Estos resultados ponen de relieve el potencial de avance tecnológico de la agricultura de precisión mediante la combinación de inteligencia artificial e imágenes.

La carencia de herramientas eficientes para la detección de la antracnosis en los cultivos de mango en Piura es un problema significativo. Las técnicas tradicionales de detección resultan insuficientes para satisfacer la necesidad de un monitoreo constante y preciso, lo que condujo retrasos en la aplicación de medidas de control y facilitó la propagación de la enfermedad [10]. En tal contexto surgió el interrogante, ¿cuál será el impacto del uso de tecnologías de visión artificial en la identificación de la antracnosis en frutos de mango? Por lo tanto, resultó imperativo investigar el potencial impacto económico y en la seguridad alimentaria que podría generar la aplicación de visión artificial en la detección de esta enfermedad. Esta tecnología promete una detección rápida y precisa, facilitando la aplicación oportuna de medidas de control efectivas [11]. Esto, a su vez, conducirá a una reducción de las pérdidas en la producción, al aumento de la calidad de la cosecha y a un impulso en la sostenibilidad del cultivo del mango en la región.

Para desglosar este problema central, se plantearon varias preguntas específicas que abordaron aspectos clave de la implementación de tecnologías de visión artificial en la detección de la antracnosis en los cultivos de mango de Piura. Estas preguntas se centraron en la utilización de imágenes digitales y algoritmos de aprendizaje automático, así como en la precisión y fiabilidad de los sistemas de visión artificial en diferentes condiciones.

En primer lugar, se cuestionará ¿cómo las imágenes digitales pueden contribuir al desarrollo de un modelo de visión artificial? Esta pregunta fue crucial para comprender cómo los datos visuales podían ser procesados y analizados para identificar patrones específicos relacionados con la incidencia de antracnosis en los frutos de mango.

Luego, se planteó la interrogante sobre ¿cuáles serán los mejores algoritmos de aprendizaje automático para identificar estos patrones de antracnosis? Esto implicó la evaluación de diversos algoritmos y técnicas de machine learning para determinar ¿cuáles eran los más efectivos en la detección precisa de la enfermedad?

Además, se exploró ¿cómo se podía entrenar una red neuronal específicamente para la detección de antracnosis en mango? Esta pregunta abordó el proceso de capacitación de modelos de visión artificial para que puedan reconocer de manera confiable los síntomas característicos de la enfermedad en las imágenes de los frutos.

Finalmente, se evaluó la exactitud y confiabilidad de los sistemas de visión artificial para identificar la antracnosis en escenarios de campo y laboratorio. Este aspecto fue esencial para validar la efectividad de las soluciones desarrolladas en entornos reales de producción agrícola.

La visión artificial, mediante redes neuronales convolucionales (CNN), presentó un potencial significativo para la detección temprana de enfermedades en cultivos [12]. Estudios previos han demostrado precisiones superiores al 83% en la detección de antracnosis utilizando estas tecnologías. Los hallazgos de este estudio contribuyeron significativamente al conocimiento sobre las posibilidades y restricciones de estas tecnologías innovadoras en el contexto de la agricultura de precisión, estableciendo una base firme para futuras investigaciones y aplicaciones futuras.

La carencia de métodos efectivos para la detección de la antracnosis desencadenaron una propagación descontrolada de esta enfermedad, comprometiendo la sostenibilidad de los cultivos de mango en la región y poniendo en peligro la seguridad alimentaria tanto a nivel local como regional [13].

El Objetivo de Desarrollo Sostenible 12 de las Naciones Unidas (ODS 12) pretende minimizar las pérdidas de alimentos durante las fases de producción y postcosecha dentro de las cadenas de suministro, lo que es clave para la sostenibilidad.

Identificar y abordar los contribuyentes a estas pérdidas es crucial, especialmente en frutas altamente perecederas como los mangos. Los trastornos internos (ID) a menudo agravan las pérdidas poscosecha y el desperdicio. Este estudio no solo contribuyó a reducir estas pérdidas, sino que también se alinea con el Objetivo de Desarrollo Sostenible 2: Hambre Cero, al proponer soluciones que mejoren la productividad agrícola y fortalezcan la seguridad alimentaria en la región [14]. A través de la implementación de una herramienta accesible para los agricultores de Piura, este estudio permitió la identificación precoz de la antracnosis en los cultivos de mango, facilitando la adopción de medidas de control oportunas, reduciendo pérdidas económicas y optimizando la calidad y la productividad de las cosechas. Esto contribuyó a la reducción de pérdidas en toda la cadena de suministro, cumpliendo con los objetivos de sostenibilidad y seguridad alimentaria.

La investigación propuso desarrollar un sistema de visión artificial basado en redes neuronales convolucionales para la detección de antracnosis en cultivos de mango en la región de Piura, con una precisión objetivo del 85% en condiciones de campo. Para alcanzar este objetivo, se desarrolló un conjunto de datos bien balanceado incluyendo imágenes representativas de cultivos de mango afectados y no afectados por antracnosis, con etiquetas precisas para su posterior entrenamiento y evaluación del modelo de visión artificial; diseñar un algoritmo de visión artificial adecuado para la detección de antracnosis en las imágenes de los cultivos de mango, validando su desempeño a través de métricas de precisión, sensibilidad y especificidad; evaluar el rendimiento del aplicativo de visión artificial desarrollado en condiciones reales de campo, realizando pruebas en cultivos de mango afectados por antracnosis en la región de Piura a fin de determinar su efectividad y utilidad práctica.

En la revisión de estudios previos sobre el uso de la visión artificial en la detección de antracnosis, destacó un artículo publicado por la Revista de la Universidad Rey Saud - Ciencias de la Información y la Computación. Este estudio analizó la importancia de la automatización en la ciencia agrícola, enfocándose en la clasificación y evaluación de la calidad de frutas y verduras. Según A. Bhargava y

A. Bansal [15], la adopción de la visión por computadora ha sido una solución prometedora en este ámbito. Varios investigadores han desarrollado algoritmos para mejorar la clasificación basándose en diferentes parámetros como color, textura, tamaño, forma y defectos. Este artículo ofrece una descripción exhaustiva de los métodos empleados en el preprocesamiento, segmentación, extracción de características y clasificación, proporcionando una comparación crítica de los distintos algoritmos propuestos hasta la fecha.

Complementando este enfoque, un segundo artículo publicado en la revista Computadoras y Electrónica en la Agricultura abordó la detección temprana de antracnosis en olivos utilizando imágenes Hiperespectrales junto con técnicas avanzadas de Deep Learning (DL) y redes neuronales convolucionales (CNN). Yang *et al.* [16] destacó la alta efectividad del modelo para identificar aceitunas infectadas, con una sensibilidad que alcanzó el 85% al tercer día y el 100% en los días subsiguientes. Estos resultados fueron especialmente relevantes desde una perspectiva comercial, ya que permitieron la identificación temprana de un gran número de frutos infectados. La metodología presentada incluyó el cálculo de índices de rendimiento del modelo, evaluados en términos de precisión, sensibilidad y especificidad. Además, se realizó una comparación del desempeño del modelo propuesto con otros modelos alternativos y diversas configuraciones de diseño, subrayando su superioridad en la detección de antracnosis.

Por su parte, el estudio realizado por Palacios Vargas [17], en Perú representó un avance significativo al uso de la visión artificial para la identificación de la antracnosis en mangos. La investigación se centró en desarrollar un sistema eficiente y preciso que permita detectar automáticamente esta enfermedad fúngica, respondiendo a una necesidad crítica en el sector agroexportador peruano, que había mostrado un crecimiento notable desde el año 2000.

Utilizando la tarjeta Jetson Nano de NVIDIA como controlador, los resultados del modelo fueron impresionantes. Durante la etapa de entrenamiento, el modelo alcanzó una precisión del 83.37% y una exactitud del 82.35%. Más impresionante

aún, durante las pruebas con mangos reales en la Jetson Nano, la precisión y exactitud aumentaron a 98.04% y 98.00%, respectivamente. Estos resultados no solo superaron las expectativas planteadas en la hipótesis, que estimaban un 95% de precisión y exactitud, sino que también demostraron la viabilidad y efectividad de la tecnología de visión artificial y redes neuronales en la mejora de los procesos de clasificación en la agroindustria.

Así mismo, se presentaron enfoques conceptuales para las variables dependientes denominada Visión artificial, también conocida como visión por computadora, la cual ha experimentado un desarrollo significativo desde sus inicios. Según International Business Machines [18], una rama de la inteligencia artificial (IA) que permite a las computadoras y sistemas obtener información relevante a partir de imágenes digitales, videos y otras entradas visuales, lo que les permite tomar decisiones o hacer recomendaciones basadas en esos datos. Así como la IA dota a las computadoras de la capacidad de pensar, la visión artificial les daba la capacidad de ver, observar y comprender. Así como otras formas de inteligencia artificial, la visión artificial tenía como propósito llevar a cabo y automatizar funciones que imitaban las habilidades humanas [19].

En el campo específico de la visión por computadora, las redes neuronales convolucionales (CNN) emergerán como una herramienta poderosa para el reconocimiento de la antracnosis en cultivos de mango. Se subrayaba que tanto la versatilidad como la eficiencia de las redes neuronales, destacan su capacidad para manejar grandes volúmenes de parámetros y su uso de algoritmos avanzados de optimización las posicionan como herramientas esenciales en el aprendizaje automático[20]. En particular, las CNN son aclamadas por su rendimiento superior en tareas de visión por computadora, consolidándose como la opción preferida para problemas como la clasificación de imágenes. Esta combinación de flexibilidad y precisión explican por qué las Redes Neuronales siguen siendo un área de intensa investigación y desarrollo en la inteligencia artificial [21].

Del mismo modo, se contó con la variable independiente, la cual fue la antracnosis en mango. Esta es un desafío importante para los agricultores, ya que esta enfermedad fúngica puede causar daños significativos a la producción.

En concordancia con [22], esta enfermedad se manifestó principalmente en las frutas, donde presentó una serie de síntomas característicos. Las frutas afectadas desarrollaron lesiones de color rojizo o café con apariencia acuosa. Estas lesiones progresaron hasta formar áreas hundidas de color café oscuro.

Aunque estas manchas generalmente no son profundas, cuando lo son, pueden impartir un sabor amargo al fruto. Este comportamiento patológico específico en las frutas son un indicador clave para la identificación y estudio de la antracnosis.

Para gestionar la calidad de los datos utilizados en estos sistemas de visión artificial, es fundamental aplicar métricas significativas que puedan sintetizar cientos de resultados analíticos detallados en pocas métricas comprensibles, reflejando eficazmente el estado general de la calidad de los datos. Estas métricas permitieron una evaluación precisa y rápida de la eficacia del sistema, facilitando la toma de decisiones y la implementación de mejoras [18].

Entre las métricas clave, el AUC (Área Bajo la Curva) se destacó como un indicador crucial de la efectividad de un clasificador. Este indicador reflejó la proporción de muestras que se clasificaron correctamente y representa la probabilidad de que el clasificador asigne una muestra positiva seleccionada al azar por encima de una muestra negativa también seleccionada al azar. La alta precisión y utilidad del AUC hacen que sea una herramienta esencial en la evaluación de modelos de clasificación en visión artificial [23].

La implementación de estos sistemas y métricas de evaluación se facilita enormemente con el uso de Python, un lenguaje de programación altamente versátil y popular en diversas áreas como el desarrollo de aplicaciones web, software, ciencia de datos y machine learning (ML). Python no solo ofrece eficiencia y facilidad de aprendizaje, sino que también se integra sin problemas con diferentes sistemas

operativos y plataformas, acelerando significativamente el ciclo de desarrollo de software. Esta flexibilidad y accesibilidad han consolidado su posición como una herramienta esencial en la programación moderna, especialmente en el desarrollo de soluciones de IA y visión por computadora [24].

Para realizar estudios detallados y validados en este ámbito, es necesario considerar la población y las muestras específicas a analizar. La población representa un grupo de individuos que comparten un espacio geográfico común, conformando una comunidad interconectada por diversas relaciones sociales, económicas y culturales. En términos estadísticos, la población se refiere al conjunto total de elementos que se estudian a través del muestreo, proporcionando una base para comprender patrones, tendencias y características que subyacen en una sociedad compleja y en constante evolución [25].

Dentro de esta población, la selección de muestras es crucial para los análisis y experimentos. La muestra se refiere a la parte que se extrae de una materia para analizarla y así poder conocer sus características. En la ciencia, las muestras son fundamentales para realizar análisis que permitan comprender mejor las propiedades y comportamientos de los materiales o sustancias estudiadas. Estas muestras pueden ser de diversos tipos, dependiendo del campo de estudio y del objeto de investigación [25].

En este contexto, se hipotetizó que el sistema de visión artificial desarrollado fue capaz de detectar la presencia de antracnosis en hojas de mango con una sensibilidad y especificidad superiores al 85%. Como hipótesis más específica, se especuló lo siguiente:

El sistema de visión artificial desarrollado tiene una capacidad estadísticamente significativa para detectar antracnosis en las hojas de mango, según lo evaluado por la prueba Chi-cuadrado.

El sistema de visión artificial tuvo una alta precisión y fiabilidad en la detección de la antracnosis en condiciones de campo, debido a su capacidad para analizar características visuales y patrones específicos de la enfermedad.

Las variables ambientales, como la iluminación, las condiciones climáticas, el tipo de suelo, la vegetación circundante, la altitud, la etapa de crecimiento del mango, la presencia de otras enfermedades o plagas, y las prácticas de manejo agrícola, influirán significativamente en la precisión y eficacia de los sistemas de visión artificial para la identificación de antracnosis en cultivos de mango.

II. METODOLOGÍA

En concordancia con el Manual de Oslo [26] la investigación se enmarcó dentro del campo de la investigación aplicada, que se define como aquella que busca obtener nuevos conocimientos, pero con un objetivo práctico específico. Así pues, para alcanzar dicho objetivo, la investigación persiguió un enfoque cuantitativo, que de acuerdo a [27] se fundamenta en la recolección y análisis de datos cuantificables de manera estadística, cuyo propósito recae en describir, explicar y cimentar las conclusiones en una métrica o cuantificación; en tal contexto el diseño usado fue no experimental, lo que en armonía con [28] implica que los investigadores no manipularon variables independientes para observar su efecto sobre las variables dependientes, en cambio, se entrenó y evaluó un modelo de aprendizaje automático utilizando un conjunto de datos preexistente de imágenes.

El enfoque y diseño encontró su justificación en el objetivo de este estudio, debido a que la temática fue desarrollar un modelo que pueda aprender a partir de datos existentes sin necesidad de realizar experimentos controlados.

Las variables consideradas en la investigación fueron dos, Presencia de antracnosis en cultivos de mango y Reconocimiento de antracnosis mediante visión artificial.

La selección de la población y muestra del presente estudio se abordó con una consideración detallada de los desafíos inherentes al contexto específico de la investigación, dada la complejidad y la dificultad logística para determinar con precisión la población de plantas de mango infectadas con antracnosis en la región de Piura, se ha optado por un enfoque de muestreo por conveniencia, Dicho enfoque se justifica porque permite una implementación más práctica y eficiente del estudio, lo cual es crucial debido a las restricciones de tiempo y recursos.

Para garantizar la validez de lo antes mencionado, fue seleccionada una población de 100 plántones de mango en un cultivo específico debido a su accesibilidad y capacidad para un trabajo continuo, de esa manera, utilizando la fórmula para poblaciones finitas con un nivel de confianza del 95% y un margen de error del 5%,

se determinó que una muestra de 80 plantones era adecuada para representar esta población, en tal contexto la selección de la muestra se llevó a cabo utilizando un enfoque de muestreo aleatorio estratificado, asegurando una representación proporcional de plantones sanos e infectados; se decidió incluir un 60% de plantones infectados y un 40% de plantones sanos, distribuyendo la muestra en 48 plantones infectados y 32 plantones sanos, lo que refleja la prevalencia de la enfermedad y facilita la evaluación del modelo de visión artificial, así pues tal balance permite evaluar el modelo y detectar los aciertos y fallos, así como los falsos positivos o falsos negativos, de este modo la combinación de muestreo por conveniencia y muestreo aleatorio estratificado asegura una muestra manejable y representativa, fortaleciendo la validez del estudio y su aplicabilidad práctica en los diferentes entornos agrícolas.

La investigación empleó la técnica de fotografía digital para recopilar imágenes de mango infectado y sano. Las imágenes fueron capturadas en diferentes contextos, desde diferentes ángulos y bajo condiciones de iluminación diferentes para garantizar la diversidad, calidad y consistencia de los datos, la recopilación se llevó a cabo usando una cámara fotográfica Nikon D7100 con un lente de 18 - 105mm, un smartphone UMIDIGI BISON con una cámara principal de 64 MP - f/1.79 CMOS, y un smartphone HUAWEI P30 Lite con una lente de 48MP (f/1.8). Las imágenes recopiladas fueron sometidas a un proceso de validación mediante las guías de observación validadas por el panel de expertos véase en los anexos, tal proceso se llevó a cabo para determinar la presencia de antracnosis en las imágenes y así poder clasificar dichas fotografías en su respectiva clase y tener un dataset consistente para los procesos realizados en este estudio.

Para analizar el rendimiento del modelo se elaboró una matriz de confusión con el fin de ver el número de verdaderos positivos, verdaderos negativos, falsos positivos y falsos negativos que se conseguían con el modelo, para posteriormente obtener la precisión, sensibilidad, especificidad y F1-Score del modelo, consiguientemente para la consistencia interna en la clasificación de las imágenes por parte del panel de expertos, se aplicó el índice de Kappa de Cohen una vez que los datos fueron

recopilados. Un valor de Kappa de Cohen superior a 0.70 sería considerado un indicador de alta consistencia interna, mientras que valores inferiores a 0.40 sugerirían una baja consistencia. Las imágenes recopiladas y validadas constituyeron el principal instrumento de recolección de datos para la investigación. No se utilizarán encuestas, cuestionarios o entrevistas, ya que el enfoque se basa en el análisis de imágenes mediante técnicas de aprendizaje automático.

En cuanto al proceso de implementar visión artificial para la detección de antracnosis, se empleó como hardware una tarjeta gráfica Nvidia Gforce RTX 3090® con soporte para la tecnología CUDA®, así mismo se eligió Python en su versión 3.10.11 como lenguaje de programación para hacer realidad el proyecto, esto debido a la gran flexibilidad de Python y su abundante suite de librerías orientadas al machine learning.

La fase uno empezó por entrenar un modelo de Red Neuronal Convolutiva (CNN) para detectar la presencia de hojas de mango en la imagen que se está intentando procesar, esto se realizó con el propósito de saber si la imagen que se está intentando cargar es una imagen válida o no; para cumplir con tal cometido se recurrió al uso de las librerías Tensor Flow 2.10.0 y numpy 1.26.4, así también en cuanto al material de entrenamiento se construyó un dataset dividido en 3 directorios, train, val y test, donde el modelo se entrenó con dos clases del directorio train (“leaves” y “no_leaves”) conteniendo 300 imágenes cada directorio, en la carpeta leaves se concentraron imágenes de hojas de mango en diferentes contextos, ángulos y condiciones de iluminación, mientras que en el otro folder se incorporaron 300 imágenes que contenían paisajes, cielos, suelo, maleza, otras plantas, otros tipos de hojas, entre muchas otras cosas adyacentes al contexto agrícola, dentro de este contexto el directorio val se construyó con la misma estructura de clases, solamente variando en cantidad de elementos siendo para tal ocasión 60 elementos para la clase “leaves” y otros 60 para la clase “no_leaves”, esto debido a que el propósito del directorio val es evitar el sobreajuste, en palabras más entendibles hacer que el modelo aprenda y no que memorice.

Con tales conceptos en mente, la CNN se compuso de una entrada de tamaño 224 x 224 con 3 canales (RGB) y las siguientes capas, 4 capas convolucionales (Conv2D), 4 capas de agrupamiento (MaxPooling2D), una capa de aplastamiento (Flatter), una capa densa (Dense) y finalmente una capa de salida (Sigmoid)




Figura 1: Estructura CNN.

Nota: Elaboración propia.

El propósito de agregar varias capas convolucionales fue detectar la características que componen una imagen, como la texturas, los bordes o patrones que en la primera convolución son simples no obstante a medida que se avanza se logran detectar patrones en profundidad y más complejos mediante la cantidad de filtros aplicados, cabe resaltar que la función de activación utilizada en cada convolución fue relu, esto debido a que la no linealidad es necesaria para que la red pueda aprender patrones más sofisticados como curvas, formas irregulares, entre otras combinaciones complejas; la imagen mostrada a continuación muestra el efecto de los filtros identificando patrones




Figura 2: Imágenes obtenidas al aplicar los filtros de la CNN.

Nota: Elaboración propia.

en el caso del pooling este no es otra cosa que reducir los parámetros o el tamaño de la salida y hacer la red más eficiente, en palabras más sencillas es disminuir las características de una imagen, pero conservar las suficientes y necesarias para la clasificación.




Figura 3: Comparación visual entre una imagen y su versión procesada tras aplicar Max Pooling.

Nota: Elaboración propia.

La consecuente tabla muestra las relaciones, el número de filtros y las dimensiones de la imagen en las capas convolucionales y de pooling

TABLA I
DETALLE DE LAS RELACIONES CLAVE ENTRE LAS CAPAS CONVOLUCIONALES Y DE POOLING.

Capa	Filtro (kernel)	Stride(S)	Dimensiones de entrada	Dimensiones de salida
Conv1 (32 filtros)	3	1	224×224×3	222×222×32
Max Pooling	2	2	222×222×32	111×111×32
Conv2 (64 filtros)	3	1	111×111×32	109×109×64
Max Pooling	2	2	109×109×64	54×54×64
Conv3 (128 filtros)	3	1	54×54×64	52×52×128
Max Pooling	2	2	52×52×128	26×26×128
Conv3 (128 filtros)	3	1	26×26×128	24×24×128
Max Pooling	2	2	24×24×128	12×12×128

Nota: Elaboración propia.

Después de aplicadas las capas de convolución más pooling, el proceso continua en una capa de aplanamiento o Flatten donde se convierte la salida tridimensional (12×12×128) en un vector unidimensional para poder conectar las características detectadas por las capas convolucionales con las capas densas, dando como salida 18432 características que fueron conectadas a 512 neuronas en la capa densa donde nuevamente se usó relu para añadir no linealidad al modelo y permitir que aprenda patrones complejos, también es preciso menciona que se aplicó una capa de Dropout o regularización donde se apagaron de manera aleatoria el 50% de las neuronas durante el entrenamiento, esto con el fin de evitar el sobreajuste, finalmente en esta etapa se usó una última capa densa de salida con la función de activación sigmoid, tal elección se realizó debido a que solo habían dos clases, en caso hubiera habido más se hubieran hecho presente funciones como softmax, pero en este caso como es un problema de clasificación binaria se usó sigmoid para convertir las salidas en probabilidades entre 0 y 1 y de esa forma obtener un

resultado y en el caso particular de este entrenamiento si la probabilidad es mayor a 0.5 entonces se predice la clase 1 que corresponde a hojas y si no entonces se predice la clase 0 que es maleza, paisajes u otros entornos que no corresponden a hojas donde buscar antracnosis.

Consiguientemente en la fase dos se trabajó en la segmentación que es el proceso mediante el cual se extrae una región de interés de una imagen a analizar, en el contexto de este estudio es segmentar las hojas de mango para proceder a buscar manchas de antracnosis y no confundir las manchas de antracnosis con otras manchas similares del ambiente. la iluminación, el ruido, entre otros, tal situación fue considerada debido a que la visión artificial para la búsqueda de antracnosis se planeó usar en condiciones de campo y no solo de laboratorio donde el entorno es controlado con buena iluminación y sin ruido.

Para hacer realidad esto, se trabajó con las librerías OpenCV 4.10.0.84 y numpy 1.26.4 que permiten trabajar con imágenes y tienen muchas funciones orientadas a la segmentación, así pues el flujo de trabajo de esta etapa comienza por convertir la imagen a HSV (Hue, Saturación, Value) que es un espacio de color que permite o facilita las tareas de segmentación basadas en tonalidades, para segmentar las hojas se trabajó con los valores 28 y 85 que corresponden la región del verde tal como se aprecia en la imagen presentada a continuación.




Figura 4: Escala HSV con graduación de Matriz (X) y Saturación (Y).

Nota: Elaboración propia.

Pero, aunque es cierto que el 28 aun entra un poco en el amarillo, esto se debe a que hay hojas de tonalidades un poco más amarillentas o verde más oscuro, así que fue necesario hacer ajustes para lograr una segmentación más precisa.



Figura 5: Variedad de tonalidades presentes en las hojas de mango destaca su diversidad cromática.

Nota: Elaboración propia.

De tal manera se consiguió una umbralización del color capaz de abarcar un rango más adecuado para las hojas obteniendo buenos resultados.




Figura 6: Resultados obtenidos tras aplicar umbralización por capas a la imagen.

Nota: Elaboración propia.

La continuación del camino hacia la segmentación de la hoja, fue crear una máscara binaria, entiéndase por máscara binaria una imagen que aísla en blanco los píxeles dentro del rango establecido y en negro lo demás, siendo esto lo que permite extraer regiones de interés de la fotografía e ignorar el ruido, no obstante la complejidad radica en la propia forma morfológica de la hoja debido a que tiene nervios que no

son exactamente verdes y algunas otras imperfecciones, además de que las condiciones de iluminación no siempre son las mismas y estas cosas afectan muchísimo a la máscara binaria que se obtiene, y es aquí donde entran en juego las operaciones morfológicas para limpiar ruido, rellenar agujeros y conectar contornos, cuya base es el uso de un kernel de 5x5 que no es más que una estructura o matriz deslizante que va recorriendo los píxeles de una imagen realizando operaciones lógicas que deciden si establecer el píxel en 1 o en 0.




Figura 7: Representación gráfica de un kernel para las operaciones morfológicas que son aplicadas a las imágenes.

Nota: *Elaboración propia.*

Conociendo esta parte teórica se pasó a implementarlo usando OpenCV que pone a la disposición los métodos MORPH_CLOSE y MORPH_OPEN, para limpiar el ruido dentro del contorno de la hoja, usando el closing para eliminar los puntos negros dentro del área blanca, y el opening para reducir el ruido exterior al área de la hoja, cuando se consiguió esto se pasó a usar findContours, también de la librería antes mencionada, con el fin de encontrar los contornos en la máscara morfológica para poder rellenar algunos agujeros que posiblemente quedaron aun después de la aplicación de las operaciones morfológicas, adicional a ello se usó contourArea para calcular el área de los contornos encontrados y se estableció el valor área en >1000 para evitar rellenar contornos pequeños que probablemente sean solo ruido.




Figura 8: Segmentación de la hoja mediante umbralización y operaciones morfológicas.

Nota: *Elaboración propia.*

Habiendo logrado la extracción de las regiones de interés para detectar indicios de antracnosis en mango, la investigación se adentró en la tercera y última fase la cual era la detección de la antracnosis en las hojas, aquí se optó por un enfoque de detección de contornos y conteo de los mismos, usando nuevamente el espacio de color HSV entre 3 y 20 para detectar las características manchas marrones de la antracnosis.



Figura 9: Resultados final de la detección de antracnosis tras el uso de CNN.

Nota: *Elaboración propia.*

Por último, el script se integró a una aplicación en Python que se subió a un host e integro flask para poder hacer una API que pudiera procesar las imágenes y devolver un resultado, dejando como resultado, un producto listo para las pruebas de campo y la evaluación de resultados.

En lo que concierne a los aspectos éticos considerados necesarios para la investigación en la Universidad César Vallejo, en este estudio se comprenden el Art 6 “de la investigación con plantas” manteniendo el respeto a la biodiversidad y asegurándose de no causar daños al medioambiente, asimismo se considera el Art 3 “principios de la integridad científica”; que lleva a garantizar la honestidad intelectual, respeto a la propiedad intelectual, la objetividad, veracidad y transparencia, finalmente se considera el Art 10 “de la originalidad de la investigación”, y el Art 8 “de la publicación de las investigaciones” debido a que el presente estudio pretende ser una investigación transparente, que respetara la propiedad intelectual y que divulgará los resultados con el fin de que otros investigadores puedan corroborar o comparar los resultados en nuevos estudios.

III. RESULTADOS

Los resultados finales se obtuvieron a partir de 80 pruebas realizadas en un cultivo de mango donde la muestra para evaluar el modelo y obtener las métricas, consistió en 48 plantones que presentaban antracnosis mientras que 32 eran plantas sanas, siendo que luego de las pruebas se encontró que de 48 plantas reales con antracnosis el algoritmo de visión artificial fue capaz de detectar correctamente la enfermedad en 45 plantas, siendo estos los verdaderos positivos (VP), en cuanto a los falsos negativos (FN) el algoritmo no fue capaz de detectar 3 casos, por otro lado se hayo que de 32 plantas sin la enfermedad, el sistema probado arrojó 31 verdaderos negativos (VN) y 1 falso positivo (FP) , teniendo una precisión del 95%

TABLA II

RESULTADOS OBTENIDOS DE LAS PRUEBAS REALIZADAS EN 80 PLANTONES DE MANGO.

Predicción \ Resultado real	Si	No
Si	45	3
No	1	31

Nota: *Elaboración propia*

En cuanto al objetivo uno, desarrollar un conjunto de datos de alta calidad, se puede concluir que este objetivo se cumplió satisfactoriamente. Los resultados obtenidos durante la evaluación del modelo reflejan que el conjunto de datos utilizado para el entrenamiento estaba bien balanceado, ya que las métricas de desempeño, como el recall (93.75%) y la especificidad (96.88%), mostraron un equilibrio notable en la detección tanto de plantas infectadas como sanas. Además, el índice de Kappa de Cohen (0.897) confirma una alta concordancia entre las predicciones del modelo y las condiciones reales observadas en campo, lo que indica que el dataset representó adecuadamente ambas clases sin sesgo hacia una de ellas. Esto demuestra que el conjunto de datos fue diseñado y curado de manera adecuada,

proporcionando una base sólida para alcanzar los objetivos planteados en la investigación.

En relación con el segundo objetivo, diseñar un algoritmo de visión artificial adecuado para la detección de antracnosis en las imágenes de los cultivos de mango, los resultados obtenidos reflejan un desempeño robusto del modelo. La precisión general alcanzó un 95%, indicando una alta proporción de predicciones correctas sobre el total de pruebas realizadas. Asimismo, la sensibilidad (93.75%) demuestra que el algoritmo es altamente eficaz para detectar plantas infectadas, mientras que la especificidad (96.88%) asegura que las plantas sanas fueron correctamente identificadas en la mayoría de los casos. El índice de Kappa de Cohen (0.897) refuerza la fiabilidad del modelo al evidenciar una excelente concordancia entre las predicciones y las observaciones reales. Estos resultados validan que el algoritmo diseñado cumple con los estándares de desempeño requeridos para la detección precisa de antracnosis en cultivos de mango.




Figura 10: Diagrama de barras - Resultados de las métricas

Nota: Elaboración propia

Los resultados alcanzados en esta investigación están en línea con hallazgos recientes en el campo del diagnóstico de enfermedades vegetales mediante redes neuronales convolucionales. Por ejemplo, Kim et al. [29] lograron una precisión cercana al 96% al aplicar CNNs para detectar antracnosis en frutos de pimiento chili, demostrando que estas arquitecturas pueden identificar con eficacia patrones visuales complejos en imágenes agrícolas, incluso bajo condiciones variables de campo. Este respaldo experimental refuerza la validez técnica del enfoque adoptado en nuestro sistema.

De igual manera, Rinanda et al. [30] implementaron un modelo CNN para la clasificación de enfermedades foliares en mango, obteniendo hasta un 96.87% de precisión, una sensibilidad elevada y buena generalización, lo que evidencia que los métodos de visión artificial basados en aprendizaje profundo son altamente adecuados para escenarios agrícolas reales. Estos antecedentes bibliográficos fortalecen la fiabilidad de nuestros resultados, al demostrar que modelos similares en estructuras y aplicación han alcanzado métricas comparables bajo condiciones equivalentes.

Respecto al tercer objetivo, evaluar el rendimiento del aplicativo de visión artificial desarrollado en condiciones reales de campo, los resultados obtenidos confirman su efectividad y utilidad práctica. Durante las pruebas realizadas en cultivos de mango en la región de Piura, el modelo alcanzó una precisión general del 95%, superando el umbral del 85% establecido como meta en esta investigación. Esto demuestra su capacidad para operar eficientemente en ambientes no controlados, enfrentando condiciones como variaciones de luz, ángulos de captura y heterogeneidad de las plantas. La alta sensibilidad y especificidad logradas garantizan una detección confiable tanto de plantas infectadas como de sanas, lo que respalda su implementación como una herramienta práctica para apoyar a los agricultores en el diagnóstico temprano de la antracnosis, contribuyendo al manejo efectivo de esta enfermedad.

Para dar solidez a lo antes mencionado, se usó también la prueba de Chi-cuadrado

aplicada a la matriz de confusión mostrando esta un p-valor de $[6.09e-15]$, lo que indica que la relación entre las predicciones del modelo y las condiciones reales de la enfermedad es estadísticamente significativa, y que las diferencias observadas no son atribuibles al azar.




Figura 11: Prueba de Chi-cuadrado: Región de aceptación y rechazo

Nota: Elaboración propia

Esto se mostraría en concordancia con Pandey [31] que en un estudio sobre identificación de enfermedades en las hojas de las plantas mediante imágenes capturadas en el mundo real, entrenó una red CNN densa con módulos de atención usando 10,851 imágenes de campo obtenidas con un teléfono móvil, alcanzando una precisión del 97.33% en la clasificación de 44 categorías de enfermedades, estos resultados muestran que las CNN pueden operar con alta eficacia incluso ante variaciones lumínicas y complejidad de fondo, lo cual coincide con nuestros hallazgos y refuerza la confianza en el rendimiento del sistema propuesto en ambientes no controlados, de tal forma estudios como el llevado a cabo por Pandey [31] demuestran que las CNN, bien entrenadas con datos de campo, son capaces de identificar enfermedades con gran precisión en escenarios agrícolas reales.

IV. DISCUSIÓN

Los resultados obtenidos demuestran la alta efectividad del sistema de visión artificial para la detección de antracnosis en cultivos, alcanzando una precisión del 95%, una sensibilidad del 93.75% y una especificidad del 96.88%. Estos valores superan el umbral objetivo del 85% y se alinean con estudios previos realizados en condiciones controladas, como los de Palacios Vargas (98.04%) y Bermúdez (100%)[9], [17]. Sin embargo, la precisión más baja observada en nuestro estudio puede atribuirse al desafío adicional de operar en condiciones de campo no controladas. Factores ambientales, como la iluminación variable (850 ± 150 lux) y los ángulos de captura diversos ($45\pm15^\circ$), afectan el rendimiento del sistema.

La arquitectura CNN de cuatro capas se eligió por su balance entre complejidad computacional y precisión, lo que es adecuado para aplicaciones en el campo, donde los recursos de hardware pueden ser limitados. Sin embargo, se podría considerar el uso de arquitecturas más complejas, como las redes residuales, que podrían mejorar el rendimiento sin sacrificar demasiada eficiencia computacional. La elección de la arquitectura también estuvo influenciada por las recomendaciones de Bhatt et al [21], quienes sugieren que arquitecturas ligeras son óptimas para aplicaciones agrícolas.

El preprocesamiento de las imágenes fue otro componente clave para el éxito del sistema. Las técnicas basadas en el modelo de color HSV y las operaciones morfológicas permitieron mitigar el impacto de las variaciones en la iluminación y los ángulos de captura. Sin embargo, el umbral HSV seleccionado (28-85) presenta limitaciones, especialmente ante variaciones extremas de iluminación. En futuras investigaciones, podrían explorarse técnicas de segmentación adaptativa que ajusten dinámicamente los umbrales en función de las condiciones del entorno. Alternativamente, se podrían incorporar sensores multiespectrales, como sugieren Yang et al.[16], para mejorar la detección temprana de la antracnosis, ya que estos sensores pueden captar información en longitudes de onda invisibles para el ojo humano, lo que podría proporcionar indicadores más precisos y detallados.

En uno de los estudios realizados por A. Bhargava y A. Bansal [15] resaltó la efectividad de segmentar las imágenes antes de proceder con la detección, coincidiendo con nuestro enfoque de preprocesamiento para mejorar la precisión en condiciones de campo. Según Bhargava y Bansal [15], la segmentación basada en parámetros como color, textura y forma es clave para optimizar el rendimiento de los sistemas de visión artificial en la agricultura.

Los resultados sugieren que el sistema desarrollado podría contribuir significativamente al manejo preventivo de la antracnosis en la región Piura, donde la antracnosis representa una de las principales razones de pérdidas en la producción de mango, como lo indica López Castro [5], las pérdidas por esta enfermedad impactan significativamente la producción. Las herramientas tradicionales de detección suelen ser costosas o requieren personal especializado, lo que limita su aplicación en pequeños y medianos agricultores.

En contraste, el sistema desarrollado es una solución asequible y económica que combina precisión y facilidad de uso, lo que lo convierte en una herramienta viable para estos agricultores. Además, su capacidad para operar en condiciones de campo reales permite una aplicación más amplia y práctica.

Si bien los resultados son alentadores, es importante reconocer algunos desafíos pendientes. Las variaciones en condiciones ambientales, como cambios abruptos en la iluminación o la presencia de ruido significativo en las imágenes, pueden afectar la precisión del sistema. A pesar de las técnicas de segmentación y preprocesamiento utilizadas, estos factores continúan representando un reto.

Futuros estudios podrían explorar la integración de sensores multiespectrales, como sugieren Yang et al. [16], para mejorar la detección temprana de la antracnosis. Estos sensores tienen el potencial de capturar información en longitudes de onda imperceptibles para el ojo humano, como el infrarrojo cercano o el ultravioleta, lo que podría proporcionar indicadores más precisos y detallados de la presencia de la enfermedad. Al combinar estos datos con técnicas avanzadas de procesamiento de imágenes, se podrían identificar patrones característicos de la antracnosis

incluso en etapas muy tempranas, cuando los síntomas aún no son evidentes en el espectro visible. Esto permitiría una intervención oportuna, minimizando las pérdidas y mejorando la salud general de los cultivos.

Además, una línea de investigación prometedora podría centrarse en la incorporación de técnicas de segmentación semántica basadas en redes neuronales profundas. Estas técnicas no solo permitirían una identificación más detallada y precisa de las áreas afectadas, sino que también ofrecerían la posibilidad de clasificar diferentes niveles de severidad de la enfermedad. Esto sería particularmente útil en condiciones variables de campo, donde factores como sombras, suciedad en las hojas o diferencias en la textura del suelo pueden complicar la detección. Con modelos de segmentación más robustos, el sistema podría adaptarse dinámicamente a estas condiciones, incrementando su confiabilidad y aplicabilidad en situaciones reales.

Otro aspecto clave para futuros desarrollos sería la Aplicación de sistemas de aprendizaje automático en la nube. Esta estrategia podría facilitar el análisis en tiempo real al transferir la carga computacional a servidores remotos, eliminando la necesidad de utilizar hardware especializado en campo. Mediante la sincronización de datos en tiempo real y la capacidad de ejecutar modelos más complejos, esta solución ofrecería un procesamiento más rápido y eficiente, permitiendo a los agricultores recibir alertas inmediatas y recomendaciones específicas para el manejo de sus cultivos. A largo plazo, la combinación de estas tecnologías podría no solo mejorar la precisión del sistema, sino también escalar su aplicación para adaptarse a diferentes tipos de cultivos y escenarios agrícolas en diversas regiones.

La segmentación de las imágenes también jugó un papel fundamental en la precisión del sistema. Aunque el método empleado fue efectivo, existen limitaciones asociadas con la segmentación basada en parámetros como color, textura y forma, especialmente en condiciones variables del campo, como sombras o suciedad en las hojas. Futuros estudios podrían explorar técnicas de segmentación semántica basadas en redes neuronales profundas, lo que permitiría una identificación más

detallada y precisa de las áreas afectadas y la clasificación de los diferentes niveles de severidad de la enfermedad.

Finalmente, es importante reconocer que, a pesar de las mejoras tecnológicas, factores como cambios abruptos en la iluminación o la presencia de ruido significativo en las imágenes siguen siendo desafíos para la precisión del sistema. Para superar estos problemas, se sugiere la implementación de sistemas de aprendizaje automático en la nube. Esta estrategia permitiría transferir la carga computacional a servidores remotos, mejorando la velocidad de procesamiento y reduciendo la dependencia de hardware especializado en el campo.

V. CONCLUSIONES

La investigación demostró la viabilidad de implementar sistemas de visión artificial para la detección temprana de antracnosis en cultivos de mango en la región Piura. El modelo de CNN desarrollado alcanzó una precisión del 95% en condiciones de campo, superando significativamente el umbral objetivo del 85% planteado inicialmente. La arquitectura implementada demostró robustez al mantener altos niveles de sensibilidad (93.75%) y especificidad (96.88%) bajo diversas condiciones ambientales.

El conjunto de datos desarrollado proporcionó una base sólida para el entrenamiento del modelo, evidenciado por el índice Kappa de Cohen de 0.897, que confirmó la consistencia en la clasificación. La combinación de técnicas de segmentación HSV y operaciones morfológicas permitió superar los desafíos de variabilidad en condiciones de campo, estableciendo un precedente metodológico para futuras implementaciones.

Los hallazgos obtenidos contribuyeron al conocimiento existente sobre la aplicación de tecnologías de visión artificial en agricultura de precisión, específicamente en el contexto de cultivos tropicales. El sistema desarrollado representa una solución tecnológica accesible para agricultores locales, con potencial para reducir significativamente las pérdidas económicas asociadas a la detección tardía de antracnosis.

VI. RECOMENDACIONES

Para futuras investigaciones se recomienda asumir el reto de ahondar más en el tema de la detección en condiciones de campo, perfeccionando los algoritmos de detección para que sean más precisos, incluir o probar con otros métodos de segmentación más avanzados probablemente sea una ventana enorme a nuevas posibilidades en la detección de enfermedades, a recomendación de los autores investigar con la segmentación semántica es un buen paso para probar alternativas de mejora hacia lo que se podría llamar una segmentación más inteligente que no dependa de umbrales de color rígido o texturas preestablecidas, también se recomienda aumentar el tamaño del dataset siempre manteniendo un buen balance entre clases para evitar el sobreajuste y un buen etiquetado para minimizar los falsos positivos.

Indudablemente este trabajo es solo un granito de arena en comparación a la infinidad de posibilidades que existe para aportar tecnología al sector agrícola, pero la principal recomendación es atreverse e ir un paso más lejos que la tendencia actual, lo que se conoce como innovación, y en tal sentido la inclusión de sensores o imágenes multiespectrales para la detección de enfermedades es dar un plus y salir de las limitaciones de la visión artificial mejorando enormemente la precisión y confiabilidad de este tipo de tecnologías.

Finalmente, se hace un llamado a fortalecer la formación de alianzas entre instituciones académicas, empresas tecnológicas y agricultores puede acelerar el desarrollo de soluciones prácticas y accesibles que beneficien a toda la región, con lo cual, se estaría marcando un precedente en el uso de la inteligencia artificial para la agricultura, consolidando su papel como una herramienta clave para enfrentar los retos futuros en la producción sostenible.

REFERENCIAS

- [1] B. Kaur, P. S. Panesar, A. K. Anal, y S. Chu-Ky, «Recent Trends in the Management of Mango By-products», *Food Reviews International*, vol. 39, n.º 7, pp. 4159-4179, ago. 2023, doi: 10.1080/87559129.2021.2021935.
- [2] J. S. Rezende *et al.*, «Establishment of specific DRIS standards for mango cultivars Tommy Atkins, Kent and Keitt compared to generic standards in the Sub-Middle São Francisco Valley», *Journal of Plant Nutrition*, vol. 45, n.º 17, pp. 2627-2654, oct. 2022, doi: 10.1080/01904167.2022.2064294.
- [3] L. L. T. Coral y H. A. Escobar-Garcia, «Characterization of fruits of varieties of mango (*Mangifera indica*) conserved in Peru», *Rev. Bras. Frutic.*, vol. 43, p. e, abr. 2021, doi: 10.1590/0100-29452021710.
- [4] FAO, *Compendio estadístico sobre las principales frutas tropicales 2019*. FAO ;, 2020. Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://openknowledge.fao.org/handle/20.500.14283/cb0717es>
- [5] B. U. López Castro, «Tecnologías aplicadas para el diagnóstico y buen manejo de plagas en cultivo de mango, *Mangifera indica* L., 1753», bachelorThesis, BABAHOYO: UTB, 2022, 2022. Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <http://dspace.utb.edu.ec/handle/49000/13096>
- [6] A. Quintero-Mercado, F. Dagon-Bernier, A. Páez-Redondo, A. Quintero-Mercado, F. Dagon-Bernier, y A. Páez-Redondo, «Aislamientos endofíticos de *Colletotrichum* spp. a partir de hojas y ramas de mango (*Mangifera indica* L.) cultivar Azúcar en el municipio de Ciénaga, Magdalena, Colombia», *Revista de la Academia Colombiana de Ciencias Exactas, Físicas y Naturales*, vol. 43, n.º 166, pp. 65-77, mar. 2020, doi: 10.18257/raccefyn.788.
- [7] Miaoyu Song, Haomiao Wang, Zhiyi Fan, Hantang Huang, y Huiqin Ma, «Advances in sequencing and key character analysis of mango (*Mangifera indica* L.) | Horticulture Research | Oxford Academic». Accedido: 21 de

noviembre de 2024. [En línea]. Disponible en:
<https://academic.oup.com/hr/article/10/2/uhac259/6835804?login=false>

- [8] Sánchez Burgos, Katty Fiorella y Arteaga Donayre, William Alberto, «El impacto de las nuevas tecnologías aplicadas al desarrollo exportador de mangos frescos en la región costera del Perú durante los últimos 10 años». Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://repositorio.ulima.edu.pe/handle/20.500.12724/18846>
- [9] A. F. Montenegro Bermudez, «Detección y clasificación de antracnosis en mango usando imágenes hiperespectrales y técnicas de aprendizaje profundo», Trabajo de grado - Maestría, Universidad Nacional de Colombia, 2021. Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://repositorio.unal.edu.co/handle/unal/81735>
- [10] P. Kumar, S. Ashtekar, S. S. Jayakrishna, K. P. Bharath, P. T. Vanathi, y M. Rajesh Kumar, «Classification of Mango Leaves Infected by Fungal Disease Anthracnose Using Deep Learning», en *2021 5th International Conference on Computing Methodologies and Communication (ICCMC)*, abr. 2021, pp. 1723-1729. doi: 10.1109/ICCMC51019.2021.9418383.
- [11] Venkatesh, N. Y, S. T. S, S. S, y S. U. Hegde, «Transfer Learning based Convolutional Neural Network Model for Classification of Mango Leaves Infected by Anthracnose», en *2020 IEEE International Conference for Innovation in Technology (INOCON)*, nov. 2020, pp. 1-7. doi: 10.1109/INOCON50539.2020.9298269.
- [12] C. Velásquez, N. Aleixos, J. Gomez-Sanchis, S. Cubero, F. Prieto, y J. Blasco, «Enhancing anthracnose detection in mango at early stages using hyperspectral imaging and machine learning», *Postharvest Biology and Technology*, vol. 209, p. 112732, mar. 2024, doi: 10.1016/j.postharvbio.2023.112732.

- [13] L. B. Koppal, T. M. Rajesh, y K. B. Vedamurthy, «A Novel Model for Disease Identification in Mango Plant Leaves Using Multimodal Conventional and Technological Approach», en *Data Engineering and Intelligent Computing*, V. Bhateja, S. C. Satapathy, C. M. Travieso-González, y V. N. M. Aradhya, Eds., Singapore: Springer, 2021, pp. 131-140. doi: 10.1007/978-981-16-0171-2_13.
- [14] Amit Khanal *et al.*, «Impact of Fruit Maturity on Internal Disorders in Vapor Heat Treated Mango Cv. 'B74'»; Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://www.mdpi.com/2071-1050/16/13/5472>
- [15] A. Bhargava y A. Bansal, «Fruits and vegetables quality evaluation using computer vision: A review», *Journal of King Saud University - Computer and Information Sciences*, vol. 33, n.º 3, pp. 243-257, mar. 2021, doi: 10.1016/j.jksuci.2018.06.002.
- [16] R. Yang *et al.*, «Detection of abnormal hydroponic lettuce leaves based on image processing and machine learning», *Information Processing in Agriculture*, vol. 10, n.º 1, pp. 1-10, mar. 2023, doi: 10.1016/j.inpa.2021.11.001.
- [17] J. B. Palacios Vargas, «Desarrollo de un sistema de visión artificial con redes neuronales convolucionales para la identificación en tiempo real de antracnosis en mangos», *Repositorio Institucional - UTP*, 2023, Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <http://repositorio.utp.edu.pe/handle/20.500.12867/8230>
- [18] IBM, «¿Qué es la visión artificial? | IBM». Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://www.ibm.com/es-es/topics/computer-vision>
- [19] Azure, «Visión de Azure AI con OCR e IA | Microsoft Azure». Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://azure.microsoft.com/es-es/products/ai-services/ai-vision>
- [20] REVATI RAMESH, «DEVELOPMENT OF CONVOLUTIONAL NEURAL NETWORK (CNN) AND ARTIFICIAL NEURAL NETWORK (ANN) MODEL FOR

DETECTION OF LEAF SPOT OF GROUNDNUT, ANTHRACNOSE AND POWDERY MILDEW OF MANGO». Accedido: 22 de noviembre de 2024. [En línea]. Disponible en: <https://krishikosh.egranth.ac.in/assets/pdfs/web/viewer.html?file=https%3A%2F%2Fkrishikosh.egranth.ac.in%2Fserver%2Fapi%2Fcore%2Fbitstreams%2Fd10fdc00-bcbb-42d2-bc4c-24c1e56b1869%2Fcontent>

- [21] D. Bhatt *et al.*, «CNN Variants for Computer Vision: History, Architecture, Application, Challenges and Future Scope», *Electronics*, vol. 10, n.º 20, Art. n.º 20, ene. 2021, doi: 10.3390/electronics10202470.
- [22] D. A. Vera Araujo, «Manejo poscosecha para el control de la enfermedad antracnosis en papaya (Carica papaya L.)», bachelorThesis, BABAHOYO:UTB,2020, 2020. Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <http://dspace.utb.edu.ec/handle/49000/8488>
- [23] Azure, «Evaluación de los resultados de los experimentos de aprendizaje automático automatizado - Azure Machine Learning». Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://learn.microsoft.com/es-es/azure/machine-learning/how-to-understand-automated-ml?view=azureml-api-2>
- [24] Amazon, «¿Qué es Python? - Explicación del lenguaje Python - AWS», Amazon Web Services, Inc. Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://aws.amazon.com/es/what-is/python/>
- [25] R.- ASALE y RAE, «población | Diccionario de la lengua española», «Diccionario de la lengua española» - Edición del Tricentenario. Accedido: 21 de noviembre de 2024. [En línea]. Disponible en: <https://dle.rae.es/población>
- [26] OECD, *Oslo Manual 2018: Guidelines for Collecting, Reporting and Using Data on Innovation, 4th Edition*. Paris: Organisation for Economic Co-operation and Development, 2018. Accedido: 21 de noviembre de 2024. [En línea]. Disponible

en: https://www.oecd-ilibrary.org/science-and-technology/oslo-manual-2018_9789264304604-en

- [27] S. Flores y F. Anselmo, «Fundamentos epistémicos de la investigación cualitativa y cuantitativa: consensos y disensos», *Revista Digital de Investigación en Docencia Universitaria*, vol. 13, n.º 1, pp. 102-122, ene. 2019, doi: 10.19083/ridu.2019.644.
- [28] P. Cabrera-Tenecela, «Nueva organización de los diseños de investigación», *South American Research Journal*, vol. 3, n.º 1, Art. n.º 1, jun. 2023, doi: 10.5281/zenodo.8050508.
- [29] H.-I. Kim, J.-Y. Yoon, y H.-J. Ju, «Diagnosis Anthracnose of Chili Pepper Using Convolutional Neural Networks Based Deep Learning Models», *Plant Pathol J*, vol. 41, n.º 1, pp. 100-111, feb. 2025, doi: 10.5423/PPJ.OA.11.2024.0178.
- [30] P. D. Rinanda, D. N. Aini, T. A. Pertiwi, S. Suryani, y A. J. Prakash, «Implementation of Convolutional Neural Network (CNN) for Image Classification of Leaf Disease In Mango Plants Using Deep Learning Approach», *Public Research Journal of Engineering, Data Technology and Computer Science*, vol. 1, n.º 2, Art. n.º 2, feb. 2024, doi: 10.57152/predatecs.v1i2.872.
- [31] C. Pandey *et al.*, «Identification of a bio-signature for barley resistance against *Pyrenophora teres* infection based on physiological, molecular and sensor-based phenotyping», *Plant Science*, vol. 313, p. 111072, dic. 2021, doi: 10.1016/j.plantsci.2021.111072.

Anexo 4. Reporte de similitud en software Turnitin

**UNIVERSIDAD CÉSAR VALLEJO**
FACULTAD DE INGENIERÍA Y ARQUITECTURA
ESCUELA PROFESIONAL DE INGENIERÍA DE SISTEMAS
Visión Artificial Para La Detección De Antracnosis En Cultivos De Mango
En La Región Piura
TESIS PARA OBTENER EL TÍTULO PROFESIONAL DE:
INGENIERÍA DE SISTEMAS
AUTOR (ES):
Salvador Ramirez, Aaron (orcid.org/0000-0002-2264-7847)
Távora Araujo, María Elena (orcid.org/0000-0001-7897-3492)
ASESOR (A):
Dr. Távora Ramos, Anthony Paul (orcid.org/0000-0002-4158-930X)
LÍNEA DE INVESTIGACIÓN:
Tecnología de la información y comunicación
LÍNEA DE RESPONSABILIDAD SOCIAL UNIVERSITARIA:
Desarrollo sostenible y adaptación al cambio climático
PIURA – PERÚ
2024

Resumen de coincidencias

8 %

Se están viendo fuentes estándar

Ver fuentes en inglés

Coincidencias

1

Entregado a Universida...

Trabajo del estudiante

1 %

2

www.coursehero.com

Fuente de Internet

1 %

3

repositorio.ucv.edu.pe

Fuente de Internet

1 %

4

repositorio.ug.edu.ec

Fuente de Internet

<1 %

5

www.researchgate.net

Fuente de Internet

<1 %

6

hdl.handle.net

Fuente de Internet

<1 %

7

repositorio.unc.edu.pe

Fuente de Internet

<1 %

8

catalonica.bnc.cat

Fuente de Internet

<1 %

9

helvia.uco.es

Fuente de Internet

<1 %

10

worldwidescience.org

Fuente de Internet

<1 %

11

www.ja2005.ua.es

Fuente de Internet

<1 %

AI

70%

Versión solo texto del informe

Alta resolución

Activado